

NOTA DE DESVIACIÓN Y REGISTRO DE MODIFICACIONES

Hallazgos de P11.1 y medidas adoptadas (protocolo V1.1 → V1.2)

Presentado en: Seminario de Tesis II, 2026-II — Docente: Dra. (c) Liz Maribel Huancapaza Hilasaca

Elaborado por: Luis Mario Escalante Marca (tesista)

Fecha: 3 de octubre de 2026

Criterio aplicado: Se documentan los errores encontrados, las medidas tomadas y su estado; la presentación corresponde a la matriz de trazabilidad con sus modificaciones.

1. Resumen

Se ejecutaron las pruebas técnicas internas (P11.1) del chatbot Rasa NLU/DIET sobre el Corpus MPSR-Bot (54 intenciones, 9 categorías; corpus sintético). El criterio de salida no se cumple, por lo que no se avanza al pre-piloto (P11.2). El protocolo cumplió su función: detectó, antes de involucrar personas, que el desempeño estimado ronda $F1 \approx 0.65$ y que la partición fijada en P05 tiene un defecto de diseño. Las modificaciones se incorporan a la matriz (V1.2) con su estado real.

2. Resultados frente al criterio de salida

Criterio de salida de P11.1	Resultado	¿Cumple?
Conflictos en rasa data validate	0	Sí
F1 macro ≥ 0.75 en test (partición de P05)	Rasa/DIET 0.624; SVM 0.648	No
F1 macro ≥ 0.75 en validación cruzada agrupada por base_phrase_id	Rasa/DIET 0.655; SVM 0.637	No
Smoke test de las 54 intenciones con consultas nuevas	44/54 (81 %)	No

La validación cruzada nativa de Rasa arrojó 0.778, pero con fuga de paráfrasis entre entrenamiento y prueba; se descarta como estimación.

3. Errores detectados y causas

- **Corpus sintético.** Ampliarlo con frases sintéticas nuevas no mejoró la generalización (4 aciertos ganados y 7 perdidos en el smoke test: diferencia compatible con ruido, McNemar $p \approx 0.55$) y generó rebote entre intenciones vecinas (horario_mesa_partes absorbió predicciones de requisitos_mesa_partes: exactitud 0.87 $\rightarrow$ 0.53).
- **Defecto de partición (P05).** Cada intención tiene un solo grupo retenido, asignado alternadamente a validación o a test. El test mide 27 de las 54 intenciones (3 frases cada una) y la validación las otras 27: sus F1 no son comparables y la grilla se seleccionó con la mitad de las intenciones.
- **Muestras pequeñas y sin ventaja de DIET.** Con 3 frases por intención el F1 macro es muy variable; Rasa/DIET y TF-IDF + SVM resultan indistinguibles en este corpus.
- **Caso crítico corregido.** Una consulta de licencia (“abrir un restaurante”) se clasificó como fuera_de_alcance con 0.81 de confianza: esa palabra aparecía una sola vez en el entrenamiento, dentro de un ejemplo de fuera_de_alcance.

4. Medidas ya ejecutadas

Medida ejecutada	Resultado	Evidencia
Validación cruzada agrupada por base_phrase_id (StratifiedGroupKFold) en lugar de la nativa de Rasa	Nativa 0.778 (inflada por fuga) frente a 0.655 (Rasa) y 0.637 (SVM) agrupada	evidencias/ p11_1_pruebas/
Ampliación del corpus (60 frases, 20 grupos, 9 intenciones) y corrección de la causa del falso fuera_de_alcance	Corrigió las 8 fallas; sin mejora global (F1 test 0.634 $\rightarrow$ 0.624)	REPORTE_REEVALUACION.md; logs/v2_corpus648/
Respuestas del domain.yml completas (P09) y marcadas con [Verificar] las no contrastadas con el TUPA real	54/54 respuestas; 40 de 44 de trámites marcadas; rasa data validate sin conflictos	evidencias/p09_domain/

5. Modificaciones al protocolo y a la matriz

Paso / fila	Modificación (V1.1 → V1.2)	Justificación	Estado
P02 / T03 — Datos	Lote 1 de frases reales: 15 a 25 adultos de Juliaca escriben, con sus palabras, lo que preguntarían en unas 11 situaciones descritas sin palabras clave. Anónimo y con consentimiento; muestra de conveniencia.	El corpus sintético no representa el habla real.	Planificado (formularios y catálogo listos)
P05 / T05 — Partición	Entrenamiento = frases sintéticas. Validación y test = frases reales del lote 1, con las 54 intenciones en las tres particiones. Las frases reales no se usan para entrenar.	Corrige la cobertura (27 de 54 intenciones en test) y mide la generalización sobre lenguaje real.	Planificado (depende del lote 1)
P08–P09 / T06–T07 — Diálogo	Umbral de confianza (FallbackClassifier) que responde “no entendí”. Se elige en la validación real con un criterio fijado de antemano: maximizar aciertos – 2 × errores con respuesta.	Evita respuestas erróneas con alta confianza. En el smoke test, 9 de 10 errores habrían sido “no entendí” a costa de 6 de 44 aciertos (indicativo; no fija el umbral).	Planificado
P11.2 / T07.2 — Pre-piloto	Dividir en (a) recolección de lenguaje real y refinamiento, sin umbral de F1, y (b) pre-piloto formal con Alfa de Cronbach ≥ 0.70 y F1 ≥ 0.75 medido sobre el conjunto real retenido.	Exigir F1 ≥ 0.75 para entrar era circular: el pre-piloto es la vía más barata de obtener lenguaje real. El Alfa no depende del NLU. Decidido antes de observar resultados del pre-piloto.	Adoptado (vigente en V1.2)
P11 / T06 — Reporte	Comparar DIET y SVM con intervalos de confianza bootstrap y prueba pareada sobre el conjunto real.	Evitar sobreinterpretar diferencias pequeñas.	Parcial (McNemar ya aplicado al smoke test)

Criterio de presentación: cada modificación se presenta con su estado real (ejecutado, planificado o simulado). Si alguna no se ejecuta dentro del curso, se presenta como planificada, con su justificación, y no como ejecutada.

6. Limitaciones que se declaran

- Los resultados actuales provienen de un corpus sintético y no son extrapolables al lenguaje real.
- El lote 1 será una muestra de conveniencia con particiones pequeñas (alta varianza).
- Las respuestas del chatbot (domain.yml) usan información típica de un TUPA municipal peruano y deben contrastarse con el TUPA vigente de la MPSR antes del pre-piloto formal.

Evidencias: repositorio mpsr-chatbot (evidencias/, REPORTE_REEVALUACION.md e incident_log.csv, con 37 incidencias registradas).

Firma del tesista: _____