

NOTA DE DESVIACIÓN Y REGISTRO DE MODIFICACIONES

Hallazgos de P11.1 y medidas adoptadas (protocolo V1.1 → V1.8)

Presentado en: Seminario de Tesis II, 2026-II — Docente: Dra. (c) Liz Maribel Huancapaza Hilasaca

Elaborado por: Luis Mario Escalante Marca (tesista)

Fecha: 3 de octubre de 2026 (actualizada el 8 de octubre de 2026)

Criterio aplicado: Se documentan los errores encontrados, las medidas tomadas y su estado; la presentación corresponde a la matriz de trazabilidad con sus modificaciones.

1. Resumen

Se ejecutaron las pruebas técnicas internas (P11.1) del chatbot Rasa NLU/DIET sobre el Corpus MPSR-Bot (54 intenciones, 9 categorías; corpus sintético). El criterio de salida no se cumple, por lo que no se avanza al pre-piloto (P11.2). El protocolo cumplió su función: detectó, antes de involucrar personas, que el desempeño estimado ronda $F1 \approx 0.65$ y que la partición fijada en P05 tiene un defecto de diseño. Las modificaciones se incorporan a la matriz (V1.2) con su estado real.

Actualización del 8 de octubre de 2026 (datos reales). Se aplicó el lote 1 de frases reales (con sus complementos 1b y 1c: 32 participantes, 185 frases activas) y el test real se evaluó una sola vez: $F1$ macro 0.687, por debajo del criterio de 0.75 (G3 no cumplida con ese test; $IC95\%$ 0.570–0.707). Se verificaron las respuestas contra el TUPA y los canales oficiales (G4 cumplida; 0 de 44 con [Verificar]). Se aplicó después un lote 2 independiente (25 participantes nuevos, 267 frases de test) con el modelo, el umbral y los datos congelados antes de medir, y se evaluó una sola vez: $F1$ macro 0.9072 ($IC95\%$ por participantes 0.852–0.939), con lo que G3 queda cumplida con esa medición. Se congeló después el modelo medido (G5). Hoy hay 5 de 7 compuertas cumplidas con datos reales (G1 a G5). El resultado vale para el diseño declarado (mismas 56 situaciones, una sola revisora de etiquetas) y no prueba generalización a situaciones nuevas; eso lo pone a prueba el pre-piloto.

2. Resultados frente al criterio de salida

Criterio de salida de P11.1	Resultado	¿Cumple?
Conflictos en rasa data validate	0	Sí
$F1$ macro ≥ 0.75 en test (partición de P05)	Rasa/DIET 0.624; SVM 0.648	No
$F1$ macro ≥ 0.75 en validación cruzada agrupada por base_phrase_id	Rasa/DIET 0.655; SVM 0.637	No
Smoke test de las 54 intenciones con consultas nuevas	44/54 (81 %)	No
$F1$ macro ≥ 0.75 en test real (lote 1, 185 frases activas; evaluado una sola vez)	Rasa/DIET 0.687 ($IC95\%$ bootstrap 0.570–0.707)	No
$F1$ macro ≥ 0.75 en test real independiente (lote 2, 267 frases; evaluado una sola vez)	Rasa/DIET 0.9072 ($IC95\%$ por participantes 0.852–0.939)	Sí

Resultados obtenidos con el corpus v3 (708 frases). La validación cruzada nativa de Rasa arrojó 0.778, pero con fuga de paráfrasis entre entrenamiento y prueba; se descarta como estimación.

3. Errores detectados y causas

- **Corpus sintético.** Ampliarlo con frases sintéticas nuevas no mejoró la generalización (4 aciertos ganados y 7 perdidos en el smoke test: diferencia compatible con ruido, McNemar $p \approx 0.55$) y generó rebote entre intenciones vecinas (horario_mesa_partes absorbió predicciones de requisitos_mesa_partes: exactitud 0.87 → 0.53).
- **Defecto de partición (P05).** Cada intención tiene un solo grupo retenido, asignado alternadamente a validación o a test. El test mide 27 de las 54 intenciones (3 frases cada una) y la validación las otras 27: sus $F1$ no son comparables y la grilla se seleccionó con la mitad de las intenciones.
- **Muestras pequeñas y sin ventaja de DIET.** Con 3 frases por intención el $F1$ macro es muy variable; Rasa/DIET y TF-IDF + SVM resultan indistinguibles en este corpus.
- **Caso crítico corregido.** Una consulta de licencia (“abrir un restaurante”) se clasificó como fuera_de_alcance con 0.81 de confianza: esa palabra aparecía una sola vez en el entrenamiento, dentro de un ejemplo de fuera_de_alcance.

4. Medidas ya ejecutadas

Medida ejecutada	Resultado	Evidencia
Validación cruzada agrupada por base_phrase_id (StratifiedGroupKFold) en lugar de la nativa de Rasa	Nativa 0.778 (inflada por fuga) frente a 0.655 (Rasa) y 0.637 (SVM) agrupada	evidencias/p11_1_pruebas/
Ampliación del corpus (60 frases, 20 grupos, 9 intenciones) y corrección de la causa del falso fuera_de_alcance	Corrigió las 8 fallas; sin mejora global ($F1$ test 0.633 en el corpus v2 → 0.624 en el v3)	REPORTE_REEVALUACION.md; logs/v2_corpus648/

Medida ejecutada	Resultado	Evidencia
Respuestas del domain.yml completas (P09) y marcadas con [Verificar] las no contrastadas con el TUPA real	54/54 respuestas; 40 de 44 de trámites marcadas al inicio (a 08/10/2026 quedan 0 de 44); rasa data validate sin conflictos	evidencias/p09_domain/
Preparación de la Parte B: scripts de ingesta, partición V1.2, evaluación real, umbral de confianza y conciliación con el seguimiento	Pruebas de humo con datos falsos (simuladas): 59/59 y 22/22; el flujo real espera el lote 1	evidencias/v3_real/
Verificación de cifras y referencias contra el repositorio	37 afirmaciones recalculadas: 30 coincidían y 5 diferían (corregidas en esta versión)	evidencias/v3_real/ y docs/ERRATAS_protocolo_V1.2.md
Demostración simulada completa del flujo (10 etapas)	SIMULADO: 10 etapas; ninguna cifra es hallazgo de campo. Compuertas reales cumplidas: 0 de 7; 55 archivos reales sin cambios (SHA-256)	evidencias/simulado_demostracion/; protocolo 5.7
Lote 1 real (1, 1b y 1c), partición V1.2 y evaluación única en el test real	32 participantes; 185 frases activas (71 validación, 114 test); entrenamiento 707 sintéticas; F1 macro 0.687; 0 de 2 ciclos de refinamiento	logs/v3_real/ (carpeta privada fuera de Git)
Verificación del TUPA y de los canales oficiales, y aplicación a domain.yml	28 filas confirmadas por el tesista; 0 alertas; 0 de 44 con [Verificar]; humo 54/54	docs/tupa/ Verificacion_TUPA_v10_4.xlsx
Lote 2 real (P33–P57), partición del lote 2 y evaluación única	25 participantes; 280 frases, 13 excluidas por duplicado con el entrenamiento, 267 en test; F1 macro 0.9072; cobertura 92.9 %, precisión 95.6 %; 1 de 2 ciclos de refinamiento	logs/avance/ eval_lote2_notas.md (carpeta privada fuera de Git)
Congelamiento del modelo medido en el lote 2 (G5)	LOTE2-FINAL v1; 943 frases de entrenamiento; DIET 100/64/20, semilla 42, t = 0.50; verificación de integridad «intacto»; G5 cumplida (5 de 7 compuertas reales)	logs/v3_real/ modelo_congelado.json

5. Modificaciones al protocolo y a la matriz

Paso / fila	Modificación (V1.1 → V1.2)	Justificación	Estado
P02 / T03 — Datos	Lote 1 de frases reales: 15 a 25 adultos de Juliaca escriben, con sus palabras, lo que preguntarían en unas 11 situaciones descritas sin palabras clave. Anónimo y con consentimiento; muestra de conveniencia.	El corpus sintético no representa el habla real.	Ejecutado
P05 / T05 — Partición	Entrenamiento = frases sintéticas. Validación y test = frases reales del lote 1, con las 54 intenciones en las tres particiones. Las frases reales no se usan para entrenar.	Corrige la cobertura (27 de 54 intenciones en test) y mide la generalización sobre lenguaje real.	Ejecutado
P08–P09 / T06–T07 — Diálogo	Umbral de confianza (FallbackClassifier) que responde “no entendí”. Se elige en la validación real con un criterio fijado de antemano: maximizar aciertos – 2 × errores con respuesta.	Evita respuestas erróneas con alta confianza. En el smoke test, 9 de 10 errores habrían sido “no entendí” a costa de 6 de 44 aciertos (indicativo; no fija el umbral).	Ejecutado
P11.2 / T07.2 — Pre-piloto	Dividir en (a) recolección de lenguaje real y refinamiento, sin umbral de F1, y (b) pre-piloto formal con Alfa de Cronbach ≥ 0.70 y F1 ≥ 0.75 medido sobre el conjunto real retenido.	Exigir F1 ≥ 0.75 para entrar era circular: el pre-piloto es la vía más barata de obtener lenguaje real. El Alfa no depende del NLU. Decidido antes de observar resultados del pre-piloto.	Adoptado (vigente en V1.2)
P11 / T06 — Reporte	Comparar DIET y SVM con intervalos de confianza bootstrap y prueba pareada sobre el conjunto real.	Evitar sobreinterpretar diferencias pequeñas.	Parcial (McNemar ya aplicado al smoke test)
P01, P12–P13 / T01, T08–T11 — Piloto	Piloto exploratorio de 60 personas en una sola sesión asistida (línea base recordada, 3 tarjetas y encuesta de 9 ítems). Reemplaza dos visitas con 120 personas y WhatsApp. Las etapas avanzan por compuertas de criterio, no por fechas (protocolo 2.14).	Plazo corto y objetivo de mostrar viabilidad; evita el seguimiento y el abandono. Decidido antes de recoger datos.	Adoptado

Paso / fila	Modificación (V1.1 → V1.2)	Justificación	Estado
Demostración simulada completa / P02–P14	Flujo de extremo a extremo con datos simulados, rotulado «Simulado» y separado de lo real; los pasos ejecutados se marcan «Simulado (ejecutado en la demostración)» sin cambiar su estado real. Detalle y 16 fricciones: protocolo 5.7.	Demostrar el pipeline sin mezclar datos simulados con reales.	Simulado
Lote 2 / G3 (V1.6)	Conjunto de prueba nuevo e independiente; el entrenamiento incorpora las frases reales del lote 1 (modifica la regla V1.2); G3 se mide una sola vez sobre el lote 2.	G3 no se cumplió con el test del lote 1 (0.687); no se repite esa evaluación ni se baja el umbral. Decidido antes de medir.	Ejecutado (G3 cumplida: F1 macro 0.9072, V1.7)

Criterio de presentación: cada modificación se presenta con su estado real (ejecutado, planificado o simulado). Si alguna no se ejecuta dentro del curso, se presenta como planificada, con su justificación, y no como ejecutada.

6. Limitaciones que se declaran

- El entrenamiento combina frases sintéticas y reales; el test del lote 2 usa lenguaje real de personas distintas, pero sobre las mismas 56 situaciones, con una sola revisora de etiquetas y 4 a 5 frases por intención. El F1 real no se extrapola a situaciones nuevas.
- Limitación de reparto. Cada frase es su propio grupo de partición; 28 de 31 participantes y 52 de 56 situaciones tienen frases tanto en validación como en test. Las particiones no son independientes por participante ni por situación, y la muestra es pequeña y de conveniencia: el F1 real tiene alta varianza.
- Las respuestas del chatbot (domain.yml) se contrastaron con el TUPA y los canales oficiales (28 filas confirmadas el 08/10/2026); no queda ninguna con [Verificar] (constancia_domiciliaria: costo y plazo confirmados por el tesista).
- Desviación del perfil de participantes. Tres participantes (P08, P24 y P25) indicaron no vivir en Juliaca, lo que se aparta del criterio «adultos de Juliaca»: 3 de 32 participantes (9.4 %) y 20 de 186 frases (10.8 %). Se conservan en el corpus y se declara la desviación; la lectura de los resultados debe considerarla.
- Criterio de trámite reciente. Haber realizado un trámite en los últimos 12 meses (variable tramite_12m) no es criterio de inclusión: se registra solo como observación (P26, P27 y P29–P32 respondieron «No») y no constituye desviación.
- Hallazgo sobre «gracias». Las personas usan «gracias» tanto para agradecer como para despedirse. Se reescribieron las respuestas de agradecimiento y despedida para que funcionen con ambas lecturas, y la confusión despedida ↔ agradecimiento se reporta aparte como esperada.
- Las cifras de la demostración simulada (frases generadas, predictor simulado, revisión automática) no miden lenguaje real ni el modelo ni cumplen compuertas reales.

Evidencias: repositorio mpsr-chatbot (evidencias/, REPORTE_REEVALUACION.md e incident_log.csv, con la bitácora completa de incidencias).

Decisión sobre G3 (ejecutada). El F1 macro del test del lote 1 (0.687) no alcanzó 0.75; ese test no se repitió ni se bajó el umbral. Conforme a lo declarado antes de medir, se aplicó un lote 2: (a) conjunto de prueba nuevo e independiente por personas (P33–P57); (b) entrenamiento que incorpora las frases reales del lote 1, lo que modifica la regla de la V1.2 («las frases reales no se usan para entrenar») y convierte el test del lote 1 en dato de desarrollo; (c) modelo, umbral y datos congelados con sha256 antes de abrir el test; (d) G3 medida una sola vez, solo sobre el lote 2. Estado: ejecutado; G3 cumplida con la medición del lote 2 (F1 macro 0.9072).

Lote 2: resultado (evaluado una sola vez). Rasa/DIET obtuvo F1 macro 0.9072, con IC95 % bootstrap [0.8626; 0.9290] por frases y [0.8524; 0.9385] por participantes; el límite inferior por participantes supera 0.75, así que G3 queda cumplida. Exactitud 0.8876 (237 aciertos y 30 errores). La cifra oficial cuenta cada abstención («nlu_fallback», 19 de 267, 7.1 %) como error y promedia 55 etiquetas; calculada sobre las 54 intenciones con las mismas predicciones sería 0.9240 (dato complementario). Cobertura 92.9 % (248 respondidas) y precisión de lo respondido 95.6 % (237 aciertos y 11 errores). 30 intenciones tienen F1 = 1 y 3 tienen F1 < 0.75 (licencia_funcionamiento_plazo 0.57, fuera_de_alcance 0.64 y denuncia_seguridad_ciudadana 0.67), con solo 4 a 5 frases por intención. Despedida (n = 5): 4 bien y 1 como otra intención; agradecimiento (n = 5): 4 bien y 1 como despedida. El SVM, solo informativo, dio 0.8925; DIET frente a SVM en McNemar: solo SVM acierta 10 y solo DIET acierta 14 (p = 0.541), sin diferencia demostrable.

Lote 2: cómo leer el resultado. (1) Es una medición válida en su diseño, pero no prueba generalización a situaciones nuevas: las 56 situaciones son las mismas del lote 1 (independencia por personas, no por situaciones); eso lo pone a prueba el pre-piloto (G6). (2) No es comparable con el 0.687 del lote 1: aquel F1 se calculó con argmax y con un entrenamiento sin frases reales; este incluye la abstención y se entrenó con 943 frases, incluidas las reales del lote 1. (3) La validación cruzada del lote 1 (0.787–0.799) sugería un valor menor; la diferencia se explica en buena parte por el diseño. (4) Una sola revisora de etiquetas y ningún cambio sobre 280 frases: no hay validación independiente de las etiquetas. (5) Tras la evaluación no se re-entrenó, no se cambió el umbral ni se repitió la medición, y no se abrieron los textos de los 30 errores (se listan solo por identificador). (6) Incidente: durante la preparación se mostró por descuido una frase del lote 2 (P33, S01); no intervino en predicciones ni ajustes y quedó registrada en el registro de incidentes. (7) La sección «cobertura y precisión» que imprime el script de evaluación es un artefacto (98.9 %); se usan las cifras recalculadas de las predicciones guardadas.

Congelamiento (G5). El 8 de octubre de 2026 (22:17 hora local) se congeló el modelo medido en el lote 2 (LOTE2-FINAL v1, 943 frases de entrenamiento, DIET 100/64/20, semilla 42, umbral t = 0.50), después de G3 y G4 y sin reentrenarlo; se registraron sus huellas sha256 (modelo, dominio, entrenamiento, configuración y umbral) en logs/v3_real/modelo_congelado.json y la verificación de integridad dio «intacto». El hash del dominio coincide con el del congelamiento previo al lote 2.

Firma del tesista: _____