

METODOLOGÍA, PROTOCOLO EXPERIMENTAL Y MATRIZ DE TRAZABILIDAD TÉCNICA

*Chatbot de Inteligencia Artificial (Rasa NLU / DIET classifier) para la atención ciudadana en la
Municipalidad Provincial de San Román*

Tesista: Escalante Marca, Luis Mario — Ciclo VIII, Ingeniería en Informática y Sistemas, UNAJ

Asesora: Dra. (c) Liz Maribel Huancapaza Hilasaca

Curso: Seminario de Tesis II — 2026-II — Juliaca, Puno

Protocolo Experimental V1.2 — 3 de octubre de 2026 (actualiza la V1.1)

Nota de lectura: cada paso de la Sección 3 y cada fila de la Sección 4 indica su estado (ejecutado, simulado, planificado o adoptado). Los errores detectados, las medidas tomadas y las modificaciones respecto de la V1.1 se registran en la Sección 5.

1. Planteamiento de la investigación

1.1 Objetivo general

Implementar un chatbot con inteligencia artificial para mejorar la atención al ciudadano en la Municipalidad Provincial de San Román – Juliaca.

1.2 Objetivos específicos

- OE1: Diagnosticar la situación actual de los canales de atención al ciudadano en la Municipalidad Provincial de San Román, evaluando las capacidades y limitaciones de la atención presencial y la plataforma TramiFácil.
- OE2: Diseñar e implementar la arquitectura del chatbot utilizando tecnologías de procesamiento de lenguaje natural (framework Rasa) y una base de conocimiento construida a partir del TUPA, la información institucional y los procedimientos administrativos de la MPSR.

- OE3: Medir la reducción del tiempo de respuesta a consultas ciudadanas tras la implementación del chatbot, en comparación con la atención presencial y la plataforma TramiFácil.
- OE4: Evaluar el nivel de satisfacción de los ciudadanos de Juliaca respecto a la atención brindada por el chatbot, mediante encuestas de usabilidad con escala de Likert de 5 puntos.

2. Metodología revisada

2.1 Enfoque y tipo de investigación

La investigación adopta un enfoque cuantitativo, porque el desempeño del chatbot y su efecto sobre la atención ciudadana se evalúan mediante métricas numéricas (F1-Score, tiempo de respuesta, escala Likert) y una prueba de hipótesis estadística. Es de tipo aplicada, pues emplea Rasa NLU con DIET classifier para resolver un problema concreto: la atención de consultas ciudadanas en la MPSR.

2.2 Nivel y diseño de investigación

El nivel es explicativo: se busca establecer la relación causal entre la variable independiente (Chatbot con IA — Rasa NLU/DIET classifier, OE2) y la variable dependiente (Atención al ciudadano en la MPSR, medida a través de OE1, OE3 y OE4). El diseño es pre-experimental, de un solo grupo con medición antes y después (pre-test/post-test), de temporalidad transversal, siguiendo un método hipotético-deductivo — consistente con la clasificación metodológica definida en el Cap. III de Tesis I. El pre-test corresponde al diagnóstico de OE1 (línea base de tiempos, limitaciones y satisfacción con la atención presencial) y el post-test a la medición de OE3 y OE4 tras el despliegue del chatbot, aplicados

sobre los mismos sujetos (ver Sección 2.4 sobre el tamaño de muestra y el mecanismo de recontacto).

Para la selección de la arquitectura del chatbot (OE2) se utiliza, de manera interna y previa al piloto, un diseño experimental computacional comparativo: el método de clasificación de intenciones (baseline ML vs. Rasa NLU/DIET) es la variable independiente de este sub-experimento, y las métricas de clasificación son las variables de respuesta. Este sub-experimento no reemplaza a OE2, sino que sustenta técnicamente la arquitectura que finalmente se implementa.

2.3 Unidad de análisis y datos

- Unidad de análisis de diagnóstico (OE1): cada trámite o consulta resuelto de forma presencial, reportado por el ciudadano (TramiFácil es una herramienta de uso interno del personal de la MPSR, por lo que se evalúa de forma documental y no como canal ciudadano).
- Unidad de análisis NLU (OE2): cada utterance (frase/consulta ciudadana) del Corpus MPSR-Bot, etiquetada con una de las 54 intenciones (44 de trámites y 10 conversacionales) agrupadas en 9 categorías.
- Unidad de análisis de tiempo de respuesta (OE3): cada consulta ciudadana atendida por el chatbot durante el piloto, comparada contra la línea base de OE1.
- Unidad de análisis de satisfacción (OE4): cada ciudadano encuestado (muestra n = 120, siguiendo el antecedente de Vargas Ríos, 2022).

El Corpus MPSR-Bot conservará identificador, intención, categoría, procedencia (construcción manual y plantillas coloquiales, pendiente de contrastar con el TUPA oficial;

desde V1.2, también lenguaje real del lote 1), identificador de frase base (para agrupar paráfrasis) y partición asignada.

2.4 Muestreo y tamaño de muestra

Punto de reclutamiento. La MPSR no otorgó autorización para desplegar el chatbot en su plataforma ni para realizar trabajo de campo dentro de su local (ni observación, ni un cartel/QR informativo). Por ello, el reclutamiento se realiza en estudios contables y oficinas de abogados de Juliaca, cuyos clientes acuden frecuentemente a resolver trámites ante la MPSR (licencias, tributos, documentación legal). Esto implica un muestreo no probabilístico por cuotas (no estratificado aleatorio puro): se recolecta hasta cubrir un mínimo de 3 observaciones por cada una de las 9 categorías, pero el punto de reclutamiento favorece ciertos trámites (licencias, tributos, documentación legal) y probablemente subrepresenta otros (reclamos, registro civil, servicios públicos). Esta limitación se declara explícitamente en la discusión de resultados.

Un solo grupo, medido dos veces (pre-test/post-test). Se trabaja con un único grupo de ciudadanos reclutados en los puntos anteriores, medidos primero con la Ficha de Diagnóstico P01 (línea base: tiempo aproximado por rangos, limitaciones percibidas y satisfacción actual con la atención presencial) y, tras usar el chatbot durante el piloto, vueltos a medir con el mismo instrumento adaptado (tiempo de respuesta del chatbot y encuesta de satisfacción, OE3–OE4). Al momento de aplicar la Ficha P01 se solicita un número de WhatsApp únicamente para fines de seguimiento del estudio, el cual se elimina al concluir el análisis.

Tamaño de muestra: $n = 120$. Se calcula con la fórmula para poblaciones finitas $n = (N \cdot Z^2 \cdot p \cdot q) / (e^2 \cdot (N - 1) + Z^2 \cdot p \cdot q)$, con $Z = 1.96$ (confianza 95 %), $p = q = 0.5$ (máxima variabilidad) y $e = 5 \%$, usando como N el promedio mensual de atenciones que reporte la MPSR; como referencia preliminar ($N \approx 400$ atenciones/mes, $e = 7.5 \%$) el cálculo arroja $n \approx$

120, valor que además coincide con el antecedente nacional de Vargas Ríos (2022) en un contexto municipal similar. Se fija un mínimo de 3 observaciones por categoría para asegurar representatividad de las 9 categorías (ajustable si la distribución real del reclutamiento lo permite).

Criterio de duplicados en el corpus (OE2). Dos utterances se consideran duplicadas o casi-duplicadas cuando su similitud de texto normalizado (medida con similitud de Jaccard sobre tokens o distancia de Levenshtein normalizada) es ≥ 0.90 dentro de la misma intención; en ese caso se agrupan bajo un mismo base_phrase_id en lugar de eliminarse, para no perder variabilidad léxica útil al entrenamiento.

2.4.1 Análisis de sensibilidad de n ante la incertidumbre de N

Mientras se confirma con la MPSR el promedio real de atenciones mensuales (N), se evaluó cómo varía el tamaño de muestra n para un rango razonable de N, manteniendo $Z = 1.96$, $p = q = 0.5$ y $e = 7.5\%$:

N estimado (atenciones/mes)	n resultante
250	≈ 102
300	≈ 109
400	≈ 120
500	≈ 127
600	≈ 133

Para todo N razonable entre 250 y 600 atenciones mensuales, n se mantiene entre 100 y 135. Por ello se fija $n = 120$ como valor de trabajo para el único grupo (recontactado antes y después del piloto), y se recalculará con el registro oficial de la Plataforma antes de iniciar P01; de diferir sustancialmente del rango evaluado, se documentará como incidencia (P16) y se actualizará la muestra.

2.4.2 Lote 1 de frases reales (modificación V1.2)

El Corpus MPSR-Bot es sintético (construcción manual y plantillas coloquiales), por lo que sus resultados no son extrapolables al lenguaje real. Para medir la generalización se incorpora un lote de frases reales (lote 1): entre 15 y 25 personas adultas de Juliaca, de edades y ocupaciones variadas, escriben con sus propias palabras lo que preguntarían al asistente en unas 11 situaciones descritas sin las palabras clave de cada intención. Se emplean 56 situaciones (una por intención y tres para fuera_de_alcance) repartidas en 5 formularios (A–E); con 20 participantes, cada situación queda respondida por 4 personas distintas.

La participación es voluntaria, anónima y con consentimiento informado; no se recogen nombres ni datos de contacto. Es una muestra de conveniencia y se declara como limitación. Las frases deben ser escritas por los participantes (no por el tesista ni por una IA). La intención esperada de cada frase proviene de la situación y se revisa manualmente frase por frase antes de usarla, con una segunda revisión en una submuestra y cálculo de kappa de Cohen cuando sea posible. Estado: planificado; los formularios y el catálogo de situaciones están listos.

2.5 Calidad del dataset (Corpus MPSR-Bot)

Antes de entrenar la arquitectura de OE2 se verificará: distribución de utterances por intención y categoría, duplicados y paráfrasis casi idénticas (según el umbral de 2.4), ambigüedad de etiquetado, desbalance entre las 54 intenciones y posibles fuentes de fuga de información (data leakage) cuando varias variantes de una misma frase base terminan repartidas entre entrenamiento y prueba. Toda exclusión o corrección de etiqueta quedará registrada y justificada.

2.6 Métodos a comparar (soporte técnico de OE2)

Como línea base (Machine Learning) se emplea TF-IDF + SVM (o regresión logística) sobre las utterances. Como método propuesto para la arquitectura final (Deep Learning conversacional) se emplea Rasa NLU con DIET classifier. Ambos se evalúan bajo las mismas particiones, semillas y condiciones para garantizar una comparación justa antes de fijar la arquitectura que se implementa en OE2.

2.7 Métricas

Para la clasificación de intenciones (OE2): Accuracy, Precision macro, Recall macro, F1 macro y Balanced Accuracy, además de la matriz de confusión por intención. Métrica principal: F1-Score macro, con criterio de aceptación $F1 \geq 0.85$. Para OE1/OE3: tiempo de respuesta antes y después de la implementación, con meta de reducción $\geq 60\%$. Para OE4: satisfacción ciudadana en escala Likert de 5 puntos, con meta $\geq 4.0/5.0$. Adicionalmente se documenta la disponibilidad del canal (24/7) como evidencia complementaria de OE2/OE3. Desde V1.2, las métricas sobre el conjunto real se reportan con intervalos de confianza del 95 % (bootstrap sobre frases) y la comparación entre Rasa/DIET y el baseline se contrasta con una prueba pareada (McNemar exacto) sobre las mismas frases.

2.8 Preparación y división de datos

Las utterances del Corpus MPSR-Bot pasan por normalización de texto (minúsculas, tildes, jerga local de Juliaca/Puno), limpieza y tokenización. Partición V1.1 (ejecutada): 70 % entrenamiento, 15 % validación y 15 % prueba por grupo de paráfrasis (base_phrase_id), con semilla 42 y estratificada por intención: con 4 grupos por intención, 3 pasan a entrenamiento y el cuarto se asigna alternadamente a validación o a prueba. Defecto detectado en P11.1: cada

intención queda evaluada en una sola de las dos particiones, de modo que el test mide 27 de las 54 intenciones y la validación las otras 27. Partición V1.2 (planificada, depende del lote 1):
 entrenamiento = frases sintéticas; validación y prueba = frases reales, repartidas por intención (aproximadamente mitad y mitad, con al menos una en cada una), de modo que las 54 intenciones aparezcan en las tres particiones; las frases reales no se usan para entrenar. El conjunto de prueba no se usa para ajustar hiperparámetros ni seleccionar el modelo final.

2.9 Estrategia de Machine Learning (baseline interno de OE2)

Flujo: utterance → limpieza/tokenización → vectorización TF-IDF (max_features = 5000, ngram_range = (1,2)) → clasificador → intención predicha. Hiperparámetros fijados antes del entrenamiento: SVM con kernel lineal, explorando $C \in \{0.1, 1, 10\}$ (se conserva el valor con mejor F1 en validación); alternativa de regresión logística con $C = 1.0$, max_iter = 1000.
 Semilla: 42 en todas las corridas.

2.10 Estrategia de Deep Learning conversacional (arquitectura final de OE2: Rasa NLU / DIET)

Flujo: utterance → tokenización (WhitespaceTokenizer) → featurización (CountVectorsFeaturizer, n-gramas de caracteres 1–4) → DIETClassifier (transformer) → intención + entidades → política de diálogo (stories/rules/forms) → acción/respuesta.
 Hiperparámetros fijados antes del entrenamiento: epochs $\in \{100, 150, 200\}$, batch_size $\in \{64, 128\}$ (rango recomendado por Rasa), embedding_dimension $\in \{20, 50\}$, learning_rate = 0.001, constrain_similarities = true; se conserva la combinación con mejor F1 macro en validación (early stopping con evaluate_on_number_of_examples). Semilla: 42 en todas las corridas. Esta

es la arquitectura que se construye a partir del TUPA, la información institucional y los procedimientos administrativos de la MPSR, según establece OE2.

Modificación V1.2 (planificada): umbral de confianza. Se agrega un FallbackClassifier que responde “no entendí” cuando la confianza de la intención predicha es inferior a un umbral t . El umbral se elige exclusivamente en la validación real, con un criterio fijado antes de ver resultados: t entre 0.30 y 0.80 y puntaje = aciertos con respuesta – $2 \times$ errores con respuesta (una respuesta equivocada dada con seguridad perjudica más al ciudadano que una abstención). El umbral elegido se evalúa una sola vez en test y se reportan cobertura, precisión de lo respondido, errores atrapados y aciertos perdidos. En el smoke test de P11.1, 9 de 10 errores habrían pasado a “no entendí” a costa de 6 de 44 aciertos; esa cifra es indicativa y no se usa para fijar el umbral.

2.11 Pruebas técnicas internas (control de calidad del sistema)

Antes de que cualquier persona ajena al desarrollo interactúe con el chatbot (incluido el pre-piloto de la Sección 2.12), se ejecuta una batería de pruebas puramente técnicas, realizadas por el propio tesista, sobre el sistema integrado (NLU + gestión del diálogo construida en OE2).

- Validación de datos: 'rasa data validate' para detectar conflictos o contradicciones entre stories y rules antes de entrenar el modelo de diálogo.
- Validación cruzada del NLU: 'rasa test nlu --cross-validation' sobre el Corpus MPSR-Bot, como verificación preliminar de desempeño antes de cualquier despliegue.
- Pruebas del modelo de diálogo: 'rasa test core' sobre el conjunto de stories, para confirmar que el sistema predice la acción correcta ante cada secuencia de conversación.
- Pruebas unitarias de custom actions (pytest): cada acción personalizada se prueba con entradas controladas y su salida esperada.

- Smoke test manual: el tesista recorre, vía 'rasa shell', las 54 intenciones del corpus una por una, confirmando que cada una dispara la respuesta correcta.

Criterio de salida de este nivel: cero conflictos detectados en la validación de datos, F1 preliminar razonable en la validación cruzada, y las 54 intenciones respondiendo sin errores en el smoke test. Solo al cumplirse estos tres criterios se avanza al pre-piloto con personas (Sección 2.12). Cualquier falla encontrada aquí se corrige y se documenta en `incident_log.csv` (P16) antes de continuar.

Resultado de la ejecución (estado: ejecutado; criterio de salida no cumplido). `rasa data validate`: 0 conflictos. F1 macro en test (partición de P05): Rasa/DIET 0.624 y SVM 0.648. F1 macro en validación cruzada agrupada por `base_phrase_id` (StratifiedGroupKFold): Rasa/DIET 0.655 y SVM 0.637; la validación cruzada nativa de Rasa (0.778) se descarta por fuga de paráfrasis entre entrenamiento y prueba. Smoke test con consultas nuevas: 44 de 54 intenciones correctas. Las pruebas unitarias de custom actions no aplican porque el chatbot no tiene acciones personalizadas. Al no cumplirse el criterio no se avanza al pre-piloto; las causas y las medidas adoptadas se registran en la Sección 5.

2.12 Pre-piloto y validación del instrumento (modificado en V1.2)

Modificación V1.2 (adoptada). El pre-piloto se divide en dos etapas, porque exigir $F1 \geq 0.75$ para entrar al pre-piloto era circular: el pre-piloto con personas es la vía más económica de obtener lenguaje real, y el Alfa de Cronbach del instrumento Likert no depende del desempeño del NLU. La decisión se tomó a partir de los resultados de P11.1 y antes de observar resultados del pre-piloto.

Etapla (a) — Recolección de lenguaje real y refinamiento (P11.2a). Se aplica el lote 1 (Sección 2.4.2) y, con sus resultados, se refina el chatbot (umbral de confianza, ajustes de corpus y de respuestas). No tiene umbral de F1 de entrada. Estado: planificado.

Etapla (b) — Pre-piloto formal (P11.2b). Un grupo de 5 a 15 personas (personal de la Plataforma de Atención y/o voluntarios), distinto e independiente de los 120 ciudadanos de OE4, prueba el chatbot desplegado en un entorno mínimo (widget web o canal de WhatsApp/Telegram) con un guion de 15 a 20 consultas (2 a 3 por categoría) y responde la encuesta de satisfacción; se calcula el Alfa de Cronbach (≥ 0.70 indica consistencia aceptable; si es menor, se ajustan los ítems). Estas personas no vuelven a participar en el piloto final. Estado: pendiente de la etapa (a).

Criterio de salida del pre-piloto formal. Se pasa al piloto a escala completa (P12) solo si se cumplen de manera simultánea: $F1 \geq 0.75$ sobre el conjunto real retenido (validación y test del lote 1) y Alfa de Cronbach ≥ 0.70 . El umbral de 0.75, más permisivo que el 0.85 exigido en la evaluación final de OE2, se mantiene como condición de la etapa (b). Toda incidencia detectada se registra en `incident_log.csv` (P16) y se corrige antes de avanzar.

2.13 Evaluación del efecto en la atención ciudadana (OE1 → OE3 → OE4)

Todos los métodos de clasificación se evalúan bajo las mismas condiciones (mismas particiones y semillas) para fijar la arquitectura de OE2. El efecto del chatbot sobre la atención ciudadana se evalúa mediante el diseño pre-test/post-test de un solo grupo (Sección 2.4, $n = 120$): el pre-test es el diagnóstico de OE1 (tiempos, limitaciones y satisfacción con la atención presencial) y el post-test es la medición de OE3 (tiempo de respuesta con el chatbot) y OE4 (satisfacción ciudadana), aplicados sobre los mismos sujetos. Antes de aplicar la prueba de hipótesis se verificará el supuesto de normalidad de las diferencias pre/post con la prueba de

Shapiro-Wilk ($\alpha = 0.05$): si se cumple la normalidad, se aplica la prueba t de Student para muestras pareadas; si no se cumple, se aplica su alternativa no paramétrica, la prueba de Wilcoxon (rangos con signo), manteniendo el mismo nivel de significancia $\alpha = 0.05$.

3. Protocolo experimental V1.2

El protocolo convierte la metodología en pasos concretos de ejecución. El flujo experimental general es: Corpus MPSR-Bot → auditoría → control de fuga → partición → preprocesamiento → entrenamiento (baseline y Rasa/DIET) → repeticiones → evaluación funcional → pruebas técnicas internas → recolección de lenguaje real y refinamiento → pre-piloto formal → piloto a escala completa → verificación de supuestos → análisis estadístico → reproducibilidad → incidencias.

Estados utilizados en la tabla y en la matriz: ejecutado (realizado con código y datos reales; el corpus es sintético salvo que se indique lo contrario), simulado (ejecutado con datos generados para demostrar el pipeline del curso; no son hallazgos de campo), planificado (definido y con materiales listos, aún no ejecutado) y adoptado (decisión de diseño vigente).

ID	Paso	Descripción	Estado
P01	Diagnóstico de canales actuales (OE1)	Relevar, mediante autoreporte retrospectivo (Ficha de Diagnóstico P01), la experiencia de los últimos 12 meses con la atención presencial (TramiFácil es uso interno del personal, no se reporta como canal ciudadano). Reclutamiento: estudios contables/jurídicos de Juliaca (muestreo por cuotas, mín. 3/categoría, ver Sección 2.4). Se solicita WhatsApp solo para seguimiento. Tamaño: $n=120$, fórmula de poblaciones finitas ($Z=1.96$, $p=q=0.5$, $e=5\%$, $N=\text{promedio mensual MPSR}$; referencia preliminar $n \approx 120$ con $N \approx 400$ y $e=7.5\%$). Constituye el pre-test (línea base) para OE3-OE4 sobre los MISMOS sujetos. En el curso la línea base se simuló: 120 respuestas generadas por el tesista; no es trabajo de campo real.	Simulado
P02	Adquisición y registro del corpus (OE2)	Registrar fuente (construcción manual y plantillas coloquiales, pendiente de contrastar con el TUPA oficial), fecha/versión, n° de utterances, intenciones y categorías. Crear corpus_metadata.csv con utterance_id, intent, category, source, base_phrase_id y split. V1.2: el lote 1 de frases reales (Sección 2.4.2) se registra como fuente separada.	Ejecutado (sintético); lote 1 planificado
P03	Auditoría inicial (OE2)	Verificar duplicados (similitud de Jaccard o Levenshtein normalizada ≥ 0.90 dentro de la misma intención), utterances ambiguas, distribución por intención/categoría y desbalance entre las 54 intenciones. Evidencias: corpus_audit.csv y reporte de auditoría.	Ejecutado

ID	Paso	Descripción	Estado
P04	Control de fuga por paráfrasis (OE2)	Agrupar variantes de una misma frase base (umbral de similitud ≥ 0.90) con base_phrase_id. Ningún grupo podrá aparecer repartido entre train, validation y test.	Ejecutado
P05	División de datos (OE2)	Aplicar partición 70/15/15 con semilla registrada (42); agrupar por base_phrase_id. Registrar en dataset_split.csv. El test permanece aislado hasta la evaluación final. Modificación V1.2: entrenamiento = frases sintéticas; validación y test = frases reales del lote 1, con las 54 intenciones en las tres particiones (la partición V1.1 deja 27 de 54 intenciones en test).	V1.1 ejecutado; V1.2 planificado
P06	Preprocesamiento NLU (OE2)	Normalización de texto (minúsculas, tildes, jerga local), tokenización y featurización (TF-IDF para baseline; CountVectors/embeddings para Rasa).	Ejecutado
P07	Experimento baseline (ML) (OE2)	Pipeline: utterance $\rightarrow$ TF-IDF (max_features=5000, ngram_range=(1,2)) $\rightarrow$ SVM (kernel lineal, C $\in\{0.1,1,10\}$) o regresión logística (C=1.0, max_iter=1000) $\rightarrow$ intención. Seed=42 en todas las corridas; se conserva el C con mejor F1 en validación.	Ejecutado
P08	Experimento Rasa NLU / DIET (OE2)	Pipeline Rasa: WhitespaceTokenizer + CountVectorsFeaturizer (n-gramas de caracteres 1–4) + DIETClassifier. Grilla fijada: epochs $\in\{100,150,200\}$, batch_size $\in\{64,128\}$, embedding_dimension $\in\{20,50\}$, learning_rate=0.001, constrain_similarities=true. Seed=42; se conserva la combinación con mejor F1 en validación (early stopping por evaluate_on_number_of_examples).	Ejecutado
P09	Gestión del diálogo (OE2)	Documentar stories, rules, forms y custom actions que completan la conversación con el ciudadano, usando el TUPA y la información institucional de la MPSR. Estado: 54 de 54 respuestas redactadas en domain.yml; 40 de las 44 de trámites llevan la marca [Verificar] (datos típicos de un TUPA peruano, no del TUPA real de la MPSR). V1.2: se agrega el umbral de confianza (Sección 2.10).	Respuestas ejecutadas; umbral planificado
P10	Repeticiones (OE2)	Ejecutar múltiples corridas independientes del baseline y de Rasa/DIET con semillas predefinidas (10, 20, 30, 40, 50) para estimar variabilidad.	Ejecutado
P11	Métricas de clasificación (OE2)	Calcular Accuracy, Precision macro, Recall macro, F1 macro y Balanced Accuracy, además de la matriz de confusión por intención, para cada repetición. Se fija la arquitectura final con F1 ≥ 0.85 . V1.2: el reporte sobre el conjunto real incluye IC95 % bootstrap y prueba pareada (McNemar) entre Rasa/DIET y el baseline.	Ejecutado (sintético); reporte real planificado
P11.1	Pruebas técnicas internas (OE2)	Sin involucrar personas externas: rasa data validate (conflictos), validación cruzada del NLU agrupada por base_phrase_id (la nativa de Rasa se descarta por fuga de paráfrasis) y smoke test de las 54 intenciones con consultas nuevas; las pruebas unitarias de custom actions no aplican (no hay acciones personalizadas). Criterio de salida: 0 conflictos, F1 ≥ 0.75 y 54/54 intenciones sin error. Resultado: 0 conflictos; F1 macro 0.624–0.655; 44/54. Criterio no cumplido. Ver Sección 2.11.	Ejecutado (criterio no cumplido)
P11.2a	Recolección de lenguaje real y refinamiento (OE2–OE4)	Aplicar el lote 1 de frases reales (Sección 2.4.2), evaluar en la validación y el test reales y refinar el chatbot (umbral de confianza, ajustes de corpus y de respuestas). No tiene umbral de F1 de entrada. Ver Sección 2.12.	Planificado (formularios y catálogo listos)
P11.2b	Pre-piloto formal (OE2–OE4)	Probar el chatbot con 5–15 personas ajenas a la muestra final (guion de 15–20 consultas, 2–3 por categoría), aplicarles la encuesta de satisfacción y calcular el Alfa de Cronbach. Criterio de salida: F1 ≥ 0.75 sobre el conjunto real retenido y Alfa ≥ 0.70 . Ver Sección 2.12.	Pendiente (depende de P11.2a)
P12	Despliegue piloto y medición de tiempos (OE3)	Una vez superado el pre-piloto formal (P11.2b), desplegar el chatbot en un canal propio (WhatsApp/Telegram/web — sin integración con la MPSR). Recontactar (vía WhatsApp) a los mismos sujetos de P01 para que usen el chatbot; medir su tiempo de respuesta y compararlo contra su propia línea base de P01 (post-test pareado).	Planificado

ID	Paso	Descripción	Estado
P13	Encuesta de satisfacción (OE4)	A los mismos sujetos de P01 que completaron una interacción con el chatbot (inclusión: recibieron respuesta; exclusión: conversación abandonada, o haber participado en P11.2b), aplicar la encuesta con escala Likert de 5 puntos (post-test). $n=120$, justificado con fórmula de poblaciones finitas ($Z=1.96$, $p=q=0.5$, $e=7.5\%$, $N\approx 400$) y coincidente con Vargas Ríos (2022).	Planificado
P14	Análisis estadístico (OE3–OE4)	Verificar normalidad de las diferencias pre/post (mismos sujetos) con Shapiro-Wilk ($\alpha=0.05$). Si se cumple, aplicar prueba t de Student pareada; si no, aplicar la alternativa no paramétrica Wilcoxon (rangos con signo). Formular H_0/H_1 y aplicar el criterio de decisión con $\alpha=0.05$.	Simulado (demostración del pipeline)
P15	Reproducibilidad	Conservar código, configuraciones, semillas, particiones, modelos, predicciones, métricas, logs y un README con el orden de ejecución.	Ejecutado
P16	Registro de incidencias	Documentar fecha, experimento, incidencia, decisión adoptada y justificación de toda desviación del protocolo (p. ej. reetiquetado, falla de despliegue, ajuste de ítems tras el pre-piloto).	Ejecutado (37 incidencias)

3.1 Regla fundamental de aislamiento del test

El conjunto de prueba no se utilizará para seleccionar características, ajustar hiperparámetros, elegir la arquitectura, decidir el número de épocas ni escoger el modelo final (OE2). De igual forma, el post-test de OE3/OE4 no se anticipa ni se contamina con decisiones tomadas durante el diagnóstico de OE1.

3.2 Pregunta de control

Si se solicita demostrar de dónde salió un F1-Score reportado en la tesis, debe poder identificarse: el corpus y su versión, la partición, el código, la configuración, la semilla, las predicciones y el experimento (ID) que lo produjeron. Si la respuesta es sí, existe trazabilidad experimental.

4. Matriz de trazabilidad técnica

Lógica de trazabilidad: Objetivo → actividad → datos → procedimiento → configuración → evidencia → métrica → análisis → resultado. Ejemplo: OE3 → medir tiempo de respuesta con el chatbot → registros post-test (T09) → protocolo P12 → mismas categorías que la línea base → registros de tiempo → % de reducción → evidencia de mejora en la atención ciudadana.

La columna Estado indica si cada fila está ejecutada, simulada, planificada o pendiente (definiciones en la Sección 3). Las filas T03.1, T07.2a y T07.2b son nuevas en la V1.2.

ID	Objetivo específico	Actividad	Entrada / datos	Procedimiento	Configuración / control	Evidencia verificable	Métrica / criterio	Análisis / resultado esperado	Estado
T01	OE1. Diagnosticar la situación actual de los canales de atención.	Relevar, vía autoreporte, tiempos y limitaciones de la atención presencial (TramiFácil es uso interno).	Ficha de Diagnóstico P01 (120 sujetos reclutados en estudios contables/jurídicos).	Medición retrospectiva de tiempos y cuellos de botella; se registra WhatsApp para seguimiento.	Muestra por cuotas (9 categorías), n=120 (fórmula poblaciones finitas, ver 2.4.1).	Informe de diagnóstico + base de contactos.	Tiempo promedio reportado (línea base).	Pre-test; mismos sujetos se recontactan en T08-T11.	Simulado
T02	OE1	Evaluar capacidades y limitaciones de TramiFácil.	Plataforma TramiFácil.	Análisis funcional: qué resuelve y qué no resuelve TramiFácil.	Criterios de interactividad y cobertura de trámites.	Ficha de evaluación de TramiFácil.	Nº de limitaciones documentadas.	Justificación técnica de la necesidad del chatbot.	Planificado
T03	OE2. Construir el Corpus MPSR-Bot.	Registrar el corpus.	Construcción manual y plantillas coloquiales (pendiente de contrastar con el TUPA oficial).	Crear inventario e identificadores de utterance.	Fuente y versión registradas por intención/categoría.	corpus_metadata.csv (v2)	N.º utterances, intenciones (54) y categorías (9).	Corpus identificado y documentado.	Ejecutado (sintético)
T03.1	OE2	Recolectar el lote 1 de frases reales.	15–25 adultos de Juliaca; 56 situaciones en 5 formularios (A–E); consentimiento informado.	Cada participante escribe su frase para unas 11 situaciones; transcripción literal; revisión de la etiqueta frase por frase.	Muestra de conveniencia; frases no usadas para entrenar; anonimato (sin nombres ni contacto).	Respuestas transcritas, hojas originales y revisión de etiquetas.	≥ 3 frases reales por intención; % de etiquetas modificadas en la revisión.	Conjunto de lenguaje real para validación y test (V1.2).	Planificado (formularios y catálogo listos)
T04	OE2	Auditar calidad del corpus.	Corpus registrado.	Detectar duplicados, ambigüedad y desbalance.	Criterios de inclusión/exclusión definidos.	corpus_audit.csv + reporte	Distribución e integridad por intención.	Caracterización y calidad del corpus.	Ejecutado
T05	OE2	Controlar fuga por paráfrasis y particionar.	Utterances y frase base.	Asignar base_phrase_id; separar train/val/test.	70/15/15; seed = 42; agrupado por frase base. V1.2: entrenamiento sintético; validación y test reales.	dataset_split.csv (V1.1); dataset_split_v3.csv (V1.2, planificado)	Solapamiento entre particiones = 0. + 54/54 intenciones en cada partición (V1.2).	Corpus sin fuga, partición reproducible.	V1.1 ejecutado; V1.2 planificado
T06	OE2	Implementar y comparar baseline (ML) vs. Rasa/DIET.	Utterances preprocesadas.	Entrenar TF-IDF+SVM y Rasa NLU/DIET bajo las mismas condiciones.	Hiperparámetros y semillas registrados; test aislado.	logs/BASE-*, logs/RASA-*, logs/stats_modelos.txt	F1 macro (meta ≥ 0.85), Balanced Accuracy, Precision, Recall. Sintético: Rasa 0.624; SVM 0.648 (test).	DIET no supera al baseline en el corpus sintético; se repite sobre el conjunto real con IC95 % y McNemar (V1.2).	Ejecutado (sintético); real planificado

ID	Objetivo específico	Actividad	Entrada / datos	Procedimiento	Configuración / control	Evidencia verificable	Métrica / criterio	Análisis / resultado esperado	Estado
T07	OE2	Construir la gestión del diálogo.	Intenciones y entidades reconocidas + TUPA/información institucional.	Reglas intención → respuesta fija (sin custom actions, forms ni slots). V1.2: umbral de confianza (FallbackClassifier).	Cobertura de las 9 categorías de intención.	domain.yml, rules.yml, evidencias/p09_domain/	54/54 respuestas; 40 de 44 de trámites marcadas [Verificar].	Arquitectura del chatbot implementada.	Respuestas ejecutadas; umbral planificado
T07.1	OE2	Ejecutar pruebas técnicas internas.	Chatbot funcional (T07): NLU + gestión del diálogo.	rasa data validate; validación cruzada agrupada; smoke test de las 54 intenciones (las pruebas unitarias de actions no aplican).	0 conflictos; $F1 \geq 0.75$; 54/54 intenciones sin error.	evidencias/p11_1_pruebas/; REPORTE_REEVALUACION.md	Conflictos, F1 (test y validación cruzada agrupada), intenciones correctas.	Criterio no cumplido: 0 conflictos; F1 0.624–0.655; 44/54. No se avanza al pre-piloto.	Ejecutado (criterio no cumplido)
T07.2a	OE2-OE4	Refinar el chatbot con lenguaje real (P11.2a).	Resultados de T03.1 y partición V1.2 de T05.	Evaluar en validación real; elegir el umbral de confianza; ajustar corpus y respuestas.	Sin umbral de F1 de entrada; umbral elegido con criterio fijado de antemano (aciertos – $2 \times$ errores).	Reporte de evaluación real; tabla de umbrales.	F1 macro con IC95 %; cobertura y precisión del umbral.	Chatbot refinado con evidencia sobre lenguaje real.	Planificado
T07.2b	OE2-OE4	Ejecutar el pre-piloto formal y validar el instrumento (P11.2b).	Chatbot refinado (T07.2a) + encuesta de satisfacción.	Probar con 5–15 personas ajenas a la muestra final (guion de 15–20 consultas) y aplicarles la encuesta.	$F1 \geq 0.75$ sobre el conjunto real retenido; Alfa de Cronbach ≥ 0.70 .	Resultados del guion + respuestas de la encuesta piloto.	F1 sobre el conjunto real y Alfa de Cronbach del instrumento.	Decisión de avanzar al piloto completo o corregir modelo/instrumento.	Pendiente (depende de T07.2a)
T08	OE3. Medir la reducción del tiempo de respuesta.	Desplegar el chatbot en un canal propio (WhatsApp/Telegram/web).	Chatbot funcional (OE2), validado en T07.1 y T07.2b.	Poner en producción piloto el chatbot; recontactar vía WhatsApp a los sujetos de T01.	Mismos sujetos de T01 (pareado); meta de retención ≥ 120 .	Registro de despliegue + tasa de retención.	Disponibilidad del canal (24/7).	Chatbot operativo para medición pareada.	Planificado
T09	OE3	Medir tiempo de respuesta con el chatbot.	Consultas de los mismos sujetos de T01, atendidas por el chatbot.	Registrar tiempo de respuesta por consulta (post-test).	Mismas categorías de trámite y mismos sujetos que T01.	Registros de tiempo (post-test, pareados con T01).	Tiempo promedio de respuesta (post).	Dato post-test pareado para la comparación.	Simulado (demostración)
T10	OE3	Comparar tiempos pre/post (mismo sujeto).	Línea base (T01) + tiempos del chatbot (T09), mismos sujetos.	Calcular diferencia y porcentaje de reducción del tiempo de respuesta por sujeto.	Comparación pareada; mismo criterio de medición en ambos momentos.	Tabla comparativa pre/post pareada.	% de reducción de tiempo (meta ≥ 60 %).	Evidencia cuantitativa de mejora en el tiempo de atención.	Simulado (demostración)
T11	OE4. Evaluar el nivel de satisfacción ciudadana.	Aplicar encuesta de usabilidad (post-test).	Mismos sujetos de T01 que usaron el chatbot (excluye participantes de T07.2b).	Encuesta con escala Likert de 5 puntos.	$n=120$ (Vargas Ríos, 2022), fórmula de poblaciones finitas (2.4.1).	Base de datos de encuesta, pareada con T01.	Puntaje Likert promedio (meta $\geq 4.0/5.0$).	Nivel de satisfacción post documentado, comparable a la línea base de T01.	Simulado (demostración)
T12	OE4	Analizar errores y percepción negativa.	Predicciones del chatbot + respuestas de la encuesta.	Identificar intenciones confundidas y comentarios críticos.	Criterios uniformes de análisis.	Matrices de confusión + comentarios de encuesta.	FP/FN por intención; ítems Likert bajos.	Explicación de patrones de error e insatisfacción.	Parcial (sintético ejecutado; encuesta planificada)
T13	OE1-OE4	Contrastar la hipótesis estadísticamente.	Datos pre/post de tiempo (T01, T10) y satisfacción (T11) — mismos sujetos.	Verificar normalidad de las diferencias (Shapiro-Wilk) y aplicar prueba t de Student pareada o, en su defecto, Wilcoxon.	$\alpha = 0.05$; H0/H1 formales.	Script + tabla estadística.	p-value y decisión sobre H0.	Evidencia cuantitativa del efecto del chatbot en la atención ciudadana (mismo sujeto, antes/después).	Simulado (demostración)

ID	Objetivo específico	Actividad	Entrada / datos	Procedimiento	Configuración / control	Evidencia verificable	Métrica / criterio	Análisis / resultado esperado	Estado
T14	OE1-OE4	Garantizar reproducibilidad.	Todos los experimentos.	Integrar código, configuraciones, seeds, logs y resultados.	Versionado del protocolo y del software.	Repositorio + README.md	Experimento reproducible y rastreable.	Trazabilidad completa objetivo → resultado.	Ejecutado
T15	OE1-OE4	Registrar incidencias y desviaciones del protocolo.	Cualquier desviación durante P01–P14 (falla de despliegue, reetiquetado, corte de energía, ajuste de ítems tras T07.2b, etc.).	Documentar fecha, experimento, incidencia, decisión y justificación.	Ninguna incidencia se resuelve u omite silenciosamente.	Bitácora de incidencias (incident_log.csv).	N.º de incidencias registradas y resueltas.	Historial de desviaciones justificado y auditable.	Ejecutado (37 incidencias)

4.1 Cómo interpretar la matriz

Si en la tesis se reporta un F1-Score, un porcentaje de reducción de tiempo o un valor de satisfacción, debe poder identificarse: el objetivo específico (OE1–OE4) al que corresponde, el corpus o registro de origen, la partición o muestra, el código o instrumento, la configuración, la semilla (cuando aplique), las predicciones/registros y el ID de experimento de esta matriz que lo produjo.

5. Registro de modificaciones y control de versiones

Esta sección documenta, conforme al criterio de la docente, los errores encontrados, las medidas tomadas y su estado. La presentación del trabajo corresponde a la matriz de la Sección 4 con las modificaciones aquí registradas.

5.1 Control de versiones

Versión	Cambio principal	Motivo
V1.0	Protocolo inicial: planteamiento, metodología, protocolo y matriz adaptados del modelo de la docente.	Entrega inicial de Tesis II.
V1.1	Correcciones de la revisión por pares (Ficha 1): hiperparámetros fijados, muestreo y tamaño de muestra, verificación de normalidad, fila T15 y pasos P11.1 y P11.2.	Observaciones de la Ficha 1, respondidas en la Ficha 2.
V1.2 (3 oct. 2026)	Lote 1 de frases reales, partición V1.2, umbral de confianza, P11.2 en dos etapas, columna de estado en protocolo y matriz, y correcciones de consistencia (54 intenciones; TramiFácil de uso interno).	Criterio de salida de P11.1 no cumplido, defecto de partición y corpus sintético.

5.2 Errores detectados y causas

- Corpus sintético. Ampliarlo con frases sintéticas nuevas no mejoró la generalización (4 aciertos ganados y 7 perdidos en el smoke test: diferencia compatible con ruido, McNemar $p \approx 0.55$) y generó rebote entre intenciones vecinas (horario_mesa_partes absorbió predicciones de requisitos_mesa_partes: exactitud $0.87 \rightarrow 0.53$).
- Defecto de partición (P05). Cada intención tiene un solo grupo retenido, asignado alternadamente a validación o a test. El test mide 27 de las 54 intenciones (3 frases cada una) y la validación las otras 27: sus F1 no son comparables y la grilla se seleccionó con la mitad de las intenciones.
- Muestras pequeñas y sin ventaja de DIET. Con 3 frases por intención el F1 macro es muy variable; Rasa/DIET y TF-IDF + SVM resultan indistinguibles en este corpus.

- Caso crítico corregido. Una consulta de licencia (“abrir un restaurante”) se clasificó como fuera_de_alcance con 0.81 de confianza: esa palabra aparecía una sola vez en el entrenamiento, dentro de un ejemplo de fuera_de_alcance.

5.3 Medidas ya ejecutadas

Medida ejecutada	Resultado	Evidencia
Validación cruzada agrupada por base_phrase_id (StratifiedGroupKFold) en lugar de la nativa de Rasa	Nativa 0.778 (inflada por fuga) frente a 0.655 (Rasa) y 0.637 (SVM) agrupada	evidencias/p11_1_pruebas/
Ampliación del corpus (60 frases, 20 grupos, 9 intenciones) y corrección de la causa del falso fuera_de_alcance	Corrigió las 8 fallas; sin mejora global (F1 test 0.634 → 0.624)	REPORTE_REEVALUACION.md; logs/v2_corpus648/
Respuestas del domain.yml completas (P09) y marcadas con [Verificar] las no contrastadas con el TUPA real	54/54 respuestas; 40 de 44 de trámites marcadas; rasa data validate sin conflictos	evidencias/p09_domain/

5.4 Modificaciones al protocolo y a la matriz

Paso / fila	Modificación (V1.1 → V1.2)	Justificación	Estado
P02 / T03.1	Lote 1 de frases reales: 15 a 25 adultos de Juliaca, unas 11 situaciones sin palabras clave; anónimo, con consentimiento; muestra de conveniencia.	El corpus sintético no representa el habla real.	Planificado
P05 / T05	Entrenamiento = frases sintéticas; validación y test = frases reales, con las 54 intenciones en las tres particiones.	Corrige la cobertura (27 de 54 intenciones en test) y mide la generalización real.	Planificado
P09 / T07	Umbral de confianza (FallbackClassifier) elegido en la validación real con criterio fijado de antemano: aciertos – 2 × errores con respuesta.	Evita respuestas erróneas con alta confianza.	Planificado
P11.2 / T07.2a–b	Dividir en (a) lenguaje real y refinamiento, sin umbral de F1, y (b) pre-piloto formal con Alfa ≥ 0.70 y F1 ≥ 0.75 sobre el conjunto real retenido.	Exigir F1 ≥ 0.75 para entrar era circular; el Alfa no depende del NLU. Decidido antes de observar resultados del pre-piloto.	Adoptado
P11 / T06	Comparar DIET y SVM con IC95 % bootstrap y McNemar sobre el conjunto real.	Evitar sobreinterpretar diferencias pequeñas.	Parcial

5.5 Observaciones de consistencia

- El corpus tiene 54 intenciones (44 de trámites y 10 conversacionales); la formulación de Tesis I menciona 50. Se documenta como diferencia de alcance.
- OE1 y OE3, tal como se aprobaron en Tesis I, nombran a TramiFácil como canal de comparación. TramiFácil es una herramienta de uso interno del personal de la MPSR y los ciudadanos no la usan directamente; por eso la línea base ciudadana se mide solo para la atención presencial y TramiFácil se evalúa de forma documental (T02). Se declara como ajuste de alcance.
- La línea base de P01 y el post-test de P12–P14 se simularon para demostrar el pipeline: no son hallazgos de campo.

5.6 Criterio de presentación y limitaciones

Cada modificación se presenta con su estado real (ejecutado, simulado, planificado o adoptado). Si alguna no se ejecuta dentro del curso, se presenta como planificada, con su justificación, y no como ejecutada.

- Los resultados actuales provienen de un corpus sintético y no son extrapolables al lenguaje real.
- El lote 1 será una muestra de conveniencia con particiones pequeñas (alta varianza).
- Las respuestas del chatbot (domain.yml) usan información típica de un TUPA municipal peruano y deben contrastarse con el TUPA vigente de la MPSR antes del pre-piloto formal.