

METODOLOGÍA, PROTOCOLO EXPERIMENTAL Y MATRIZ DE TRAZABILIDAD TÉCNICA

*Chatbot de Inteligencia Artificial (Rasa NLU / DIET classifier) para la atención ciudadana en la
Municipalidad Provincial de San Román*

Tesista: Escalante Marca, Luis Mario — Ciclo VIII, Ingeniería en Informática y Sistemas, UNAJ

Asesora: Dra. (c) Liz Maribel Huancapaza Hilasaca

Curso: Seminario de Tesis II — 2026-II — Juliaca, Puno

Protocolo Experimental V1.7 — 8 de octubre de 2026 (actualiza la V1.6)

Nota de lectura: cada paso de la Sección 3 y cada fila de la Sección 4 indica su estado (ejecutado, simulado, planificado o adoptado). Los errores detectados, las medidas tomadas y las modificaciones respecto de la V1.1, la V1.2 y la V1.3 se registran en la Sección 5.

1. Planteamiento de la investigación

1.1 Objetivo general

Implementar un chatbot con inteligencia artificial para mejorar la atención al ciudadano en la Municipalidad Provincial de San Román – Juliaca.

1.2 Objetivos específicos

- OE1: Diagnosticar la situación actual de los canales de atención al ciudadano en la Municipalidad Provincial de San Román, evaluando las capacidades y limitaciones de la atención presencial y la plataforma TramiFácil.
- OE2: Diseñar e implementar la arquitectura del chatbot utilizando tecnologías de procesamiento de lenguaje natural (framework Rasa) y una base de conocimiento construida a partir del TUPA, la información institucional y los procedimientos administrativos de la MPSR.

- OE3: Medir la reducción del tiempo de respuesta a consultas ciudadanas tras la implementación del chatbot, en comparación con la atención presencial y la plataforma TramiFácil.
- OE4: Evaluar el nivel de satisfacción de los ciudadanos de Juliaca respecto a la atención brindada por el chatbot, mediante encuestas de usabilidad con escala de Likert de 5 puntos.

2. Metodología revisada

2.1 Enfoque y tipo de investigación

La investigación adopta un enfoque cuantitativo, porque el desempeño del chatbot y su efecto sobre la atención ciudadana se evalúan mediante métricas numéricas (F1-Score, tiempo de respuesta, escala Likert) y una prueba de hipótesis estadística. Es de tipo aplicada, pues emplea Rasa NLU con DIET classifier para resolver un problema concreto: la atención de consultas ciudadanas en la MPSR.

2.2 Nivel y diseño de investigación

El nivel es explicativo: se busca establecer la relación causal entre la variable independiente (Chatbot con IA — Rasa NLU/DIET classifier, OE2) y la variable dependiente (Atención al ciudadano en la MPSR, medida a través de OE1, OE3 y OE4). El diseño es pre-experimental, de un solo grupo con medición antes y después (pre-test/post-test), de temporalidad transversal, siguiendo un método hipotético-deductivo — consistente con la clasificación metodológica definida en el Cap. III de Tesis I. El pre-test corresponde al diagnóstico de OE1 (línea base de tiempos, limitaciones y satisfacción con la atención presencial) y el post-test a la medición de OE3 y OE4 con el chatbot, aplicados sobre los mismos

sujetos. Modificación V1.3: en el piloto exploratorio ambas mediciones se realizan en una sola sesión asistida (la línea base es recordada y la medición con el chatbot se hace en la misma visita; ver Sección 2.4).

Para la selección de la arquitectura del chatbot (OE2) se utiliza, de manera interna y previa al piloto, un diseño experimental computacional comparativo: el método de clasificación de intenciones (baseline ML vs. Rasa NLU/DIET) es la variable independiente de este sub-experimento, y las métricas de clasificación son las variables de respuesta. Este sub-experimento no reemplaza a OE2, sino que sustenta técnicamente la arquitectura que finalmente se implementa.

2.3 Unidad de análisis y datos

- Unidad de análisis de diagnóstico (OE1): cada trámite o consulta resuelto de forma presencial, reportado por el ciudadano (TramiFácil es una herramienta de uso interno del personal de la MPSR, por lo que se evalúa de forma documental y no como canal ciudadano).
- Unidad de análisis NLU (OE2): cada utterance (frase/consulta ciudadana) del Corpus MPSR-Bot, etiquetada con una de las 54 intenciones (44 de trámites y 10 conversacionales) agrupadas en 9 categorías.
- Unidad de análisis de tiempo de respuesta (OE3): cada consulta ciudadana atendida por el chatbot durante el piloto, comparada contra la línea base de OE1.
- Unidad de análisis de satisfacción (OE4): cada ciudadano encuestado (muestra planificada n = 120 según el antecedente de Vargas Ríos, 2022; piloto exploratorio n = 60, ver Sección 2.4).

El Corpus MPSR-Bot conservará identificador, intención, categoría, procedencia (construcción manual y plantillas coloquiales, pendiente de contrastar con el TUPA oficial; desde V1.2, también lenguaje real del lote 1), identificador de frase base (para agrupar paráfrasis) y partición asignada.

2.4 Muestreo y tamaño de muestra

Punto de reclutamiento. La MPSR no otorgó autorización para desplegar el chatbot en su plataforma ni para realizar trabajo de campo dentro de su local (ni observación, ni un cartel/QR informativo). Por ello, el reclutamiento se realiza en estudios contables y oficinas de abogados de Juliaca, cuyos clientes acuden frecuentemente a resolver trámites ante la MPSR (licencias, tributos, documentación legal). Esto implica un muestreo no probabilístico por cuotas (no estratificado aleatorio puro): se recolecta hasta cubrir un mínimo de 3 observaciones por cada una de las 9 categorías, pero el punto de reclutamiento favorece ciertos trámites (licencias, tributos, documentación legal) y probablemente subrepresenta otros (reclamos, registro civil, servicios públicos). Esta limitación se declara explícitamente en la discusión de resultados.

Un solo grupo, una sola sesión (modificación V1.3). Se trabaja con un único grupo de ciudadanos reclutados en los puntos anteriores. En una sola visita asistida (unos 15 minutos), cada persona: (1) responde su experiencia previa con la atención presencial, que es la línea base recordada (Parte 1, con el mismo contenido de la Ficha de Diagnóstico P01); (2) prueba el chatbot con 3 tarjetas de situación mientras el aplicador mide el tiempo hasta una respuesta útil; y (3) responde la encuesta de satisfacción de 9 ítems, uno de ellos pareado con la satisfacción previa. No se recogen nombres ni contactos, por lo que no hay seguimiento ni abandono. El diseño original (dos visitas, con WhatsApp para recontactar) queda como la versión planificada

V1.2 y no se ejecuta por el plazo del curso. Antes de la primera sesión se congela el modelo y se registra su versión; las consultas escritas por las personas quedan como conjunto de prueba final.

Tamaño de muestra planificado (V1.2): $n = 120$. Se calcula con la fórmula para poblaciones finitas $n = (N \cdot Z^2 \cdot p \cdot q) / (e^2 \cdot (N - 1) + Z^2 \cdot p \cdot q)$, con $Z = 1.96$ (confianza 95 %), $p = q = 0.5$ (máxima variabilidad) y $e = 5\%$, usando como N el promedio mensual de atenciones que reporte la MPSR; como referencia preliminar ($N \approx 400$ atenciones/mes, $e = 7.5\%$) el cálculo arroja $n \approx 120$, valor que además coincide con el antecedente nacional de Vargas Ríos (2022) en un contexto municipal similar. Se fija un mínimo de 3 observaciones por categoría para asegurar representatividad de las 9 categorías (ajustable si la distribución real del reclutamiento lo permite).

Tamaño del piloto exploratorio (V1.3): $n = 60$ sesiones elegibles. Con 60 pares, la prueba t de Student pareada detecta, con 80 % de potencia ($\alpha = 0.05$, dos colas), efectos de $d \approx 0.37$ o mayores, y el margen de error de una proporción ($N \approx 400$, confianza de 95 %) sube a $\approx 11.7\%$ (frente a $\approx 7.5\%$ con $n = 120$). Por ello el piloto se presenta como exploratorio y no confirmatorio. Si no se completan 60 sesiones elegibles, se presenta con el n real.

Criterio de duplicados en el corpus (OE2). Dos utterances se consideran duplicadas o casi-duplicadas cuando su similitud de texto normalizado (medida con similitud de Jaccard sobre tokens o distancia de Levenshtein normalizada) es ≥ 0.90 dentro de la misma intención; en ese caso se agrupan bajo un mismo `base_phrase_id` en lugar de eliminarse, para no perder variabilidad léxica útil al entrenamiento.

2.4.1 Análisis de sensibilidad de n ante la incertidumbre de N

Mientras se confirma con la MPSR el promedio real de atenciones mensuales (N), se evaluó cómo varía el tamaño de muestra n para un rango razonable de N, manteniendo $Z = 1.96$, $p = q = 0.5$ y $e = 7.5 \%$:

N estimado (atenciones/mes)	n resultante
250	≈ 102
300	≈ 109
400	≈ 120
500	≈ 127
600	≈ 133

Para todo N razonable entre 250 y 600 atenciones mensuales, n se mantiene entre 100 y 135. Por ello se fija $n = 120$ como valor de trabajo planificado (V1.2; el piloto exploratorio de la V1.3 usa $n = 60$), y se recalculará con el registro oficial de la Plataforma antes de iniciar P01; de diferir sustancialmente del rango evaluado, se documentará como incidencia (P16) y se actualizará la muestra.

2.4.2 Lote 1 de frases reales (modificación V1.2)

El Corpus MPSR-Bot es sintético (construcción manual y plantillas coloquiales), por lo que sus resultados no son extrapolables al lenguaje real. Para medir la generalización se incorpora un lote de frases reales (lote 1): entre 15 y 25 personas adultas de Juliaca, de edades y ocupaciones variadas, escriben con sus propias palabras lo que preguntarían al asistente en unas 11 situaciones descritas sin las palabras clave de cada intención. Se emplean 56 situaciones (una por intención y tres para fuera_de_alcance) repartidas en 5 formularios (A–E); con 20 participantes, cada situación queda respondida por 4 personas distintas.

La participación es voluntaria, anónima y con consentimiento informado; no se recogen nombres ni datos de contacto. Es una muestra de conveniencia y se declara como limitación. Las frases deben ser escritas por los participantes (no por el tesista ni por una IA). La intención esperada de cada frase proviene de la situación y se revisa manualmente frase por frase antes de usarla, con una segunda revisión en una submuestra y cálculo de kappa de Cohen cuando sea posible. Estado: ejecutado (lote 1 y sus complementos 1b y 1c: 32 participantes, 185 frases activas); resultados y desviaciones en la Sección 5.8.

2.5 Calidad del dataset (Corpus MPSR-Bot)

Antes de entrenar la arquitectura de OE2 se verificará: distribución de utterances por intención y categoría, duplicados y paráfrasis casi idénticas (según el umbral de 2.4), ambigüedad de etiquetado, desbalance entre las 54 intenciones y posibles fuentes de fuga de información (data leakage) cuando varias variantes de una misma frase base terminan repartidas entre entrenamiento y prueba. Toda exclusión o corrección de etiqueta quedará registrada y justificada.

2.6 Métodos a comparar (soporte técnico de OE2)

Como línea base (Machine Learning) se emplea TF-IDF + SVM (o regresión logística) sobre las utterances. Como método propuesto para la arquitectura final (Deep Learning conversacional) se emplea Rasa NLU con DIET classifier. Ambos se evalúan bajo las mismas particiones, semillas y condiciones para garantizar una comparación justa antes de fijar la arquitectura que se implementa en OE2.

2.7 Métricas

Para la clasificación de intenciones (OE2): Accuracy, Precision macro, Recall macro, F1 macro y Balanced Accuracy, además de la matriz de confusión por intención. Métrica principal: F1-Score macro, con criterio de aceptación $F1 \geq 0.85$. Para OE1/OE3: tiempo de respuesta antes y después de la implementación, con meta de reducción $\geq 60\%$. Para OE4: satisfacción ciudadana en escala Likert de 5 puntos, con meta $\geq 4.0/5.0$. Adicionalmente se documenta la disponibilidad del canal (24/7) como evidencia complementaria de OE2/OE3. Desde V1.2, las métricas sobre el conjunto real se reportan con intervalos de confianza del 95 % (bootstrap sobre frases) y la comparación entre Rasa/DIET y el baseline se contrasta con una prueba pareada (McNemar exacto) sobre las mismas frases.

2.8 Preparación y división de datos

Las utterances del Corpus MPSR-Bot pasan por normalización de texto (minúsculas, tildes, jerga local de Juliaca/Puno), limpieza y tokenización. Partición V1.1 (ejecutada): por grupo de paráfrasis (base_phrase_id), con semilla 42 y estratificada por intención. El objetivo nominal era 70/15/15, pero con 4 grupos por intención 3 pasan a entrenamiento y el cuarto se asigna alternadamente a validación o a prueba, de modo que la proporción real en la V1.1 (corpus v2, 648 frases) es 486/81/81, es decir 75 % / 12.5 % / 12.5 %. El corpus vigente (v3, 708 frases) agrega 60 frases solo a entrenamiento; validación y test no cambian. Defecto detectado en P11.1: cada intención queda evaluada en una sola de las dos particiones, de modo que el test mide 27 de las 54 intenciones y la validación las otras 27. Partición V1.2 (planificada, depende del lote 1): entrenamiento = frases sintéticas; validación y prueba = frases reales, repartidas por intención (aproximadamente mitad y mitad, con al menos una en cada una), de modo que las 54

intenciones aparezcan en las tres particiones; las frases reales no se usan para entrenar. El conjunto de prueba no se usa para ajustar hiperparámetros ni seleccionar el modelo final.

2.9 Estrategia de Machine Learning (baseline interno de OE2)

Flujo: utterance → limpieza/tokenización → vectorización TF-IDF (max_features = 5000, ngram_range = (1,2)) → clasificador → intención predicha. Hiperparámetros fijados antes del entrenamiento: SVM con kernel lineal, explorando $C \in \{0.1, 1, 10\}$ (se conserva el valor con mejor F1 en validación); alternativa de regresión logística con $C = 1.0$, max_iter = 1000. Semilla: 42 en todas las corridas.

2.10 Estrategia de Deep Learning conversacional (arquitectura final de OE2: Rasa NLU / DIET)

Flujo: utterance → tokenización (WhitespaceTokenizer) → featurización (CountVectorsFeaturizer, n-gramas de caracteres 1–4) → DIETClassifier (transformer) → intención + entidades → política de diálogo (stories/rules/forms) → acción/respuesta. Hiperparámetros fijados antes del entrenamiento: epochs $\in \{100, 150, 200\}$, batch_size $\in \{64, 128\}$ (rango recomendado por Rasa), embedding_dimension $\in \{20, 50\}$, learning_rate = 0.001, constrain_similarities = true; se conserva la combinación con mejor F1 macro en validación (early stopping con evaluate_on_number_of_examples). Semilla: 42 en todas las corridas. Esta es la arquitectura que se construye a partir del TUPA, la información institucional y los procedimientos administrativos de la MPSR, según establece OE2.

Modificación V1.2 (ejecutada con el lote 1 real; ver Sección 5.8): umbral de confianza. Se agrega un FallbackClassifier que responde “no entendí” cuando la confianza de la intención predicha es inferior a un umbral t . El umbral se elige exclusivamente en la validación real, con

un criterio fijado antes de ver resultados: t entre 0.30 y 0.80 y puntaje = aciertos con respuesta – $2 \times$ errores con respuesta (una respuesta equivocada dada con seguridad perjudica más al ciudadano que una abstención). El umbral elegido se evalúa una sola vez en test y se reportan cobertura, precisión de lo respondido, errores atrapados y aciertos perdidos. En el smoke test de P11.1, 9 de 10 errores habrían pasado a “no entendí” a costa de 6 de 44 aciertos; esa cifra es indicativa y no se usa para fijar el umbral.

2.11 Pruebas técnicas internas (control de calidad del sistema)

Antes de que cualquier persona ajena al desarrollo interactúe con el chatbot (incluido el pre-piloto de la Sección 2.12), se ejecuta una batería de pruebas puramente técnicas, realizadas por el propio tesista, sobre el sistema integrado (NLU + gestión del diálogo construida en OE2).

- Validación de datos: 'rasa data validate' para detectar conflictos o contradicciones entre stories y rules antes de entrenar el modelo de diálogo.
- Validación cruzada del NLU: 'rasa test nlu --cross-validation' sobre el Corpus MPSR-Bot, como verificación preliminar de desempeño antes de cualquier despliegue.
- Pruebas del modelo de diálogo: 'rasa test core' sobre el conjunto de stories, para confirmar que el sistema predice la acción correcta ante cada secuencia de conversación.
- Pruebas unitarias de custom actions (pytest): cada acción personalizada se prueba con entradas controladas y su salida esperada.
- Smoke test manual: el tesista recorre, vía 'rasa shell', las 54 intenciones del corpus una por una, confirmando que cada una dispara la respuesta correcta.

Criterio de salida de este nivel: cero conflictos detectados en la validación de datos, F1 preliminar razonable en la validación cruzada, y las 54 intenciones respondiendo sin errores en el smoke test. Solo al cumplirse estos tres criterios se avanza al pre-piloto con personas (Sección

2.12). Cualquier falla encontrada aquí se corrige y se documenta en incident_log.csv (P16) antes de continuar.

Resultado de la ejecución (estado: ejecutado con el corpus v3, de 708 frases; criterio de salida no cumplido). rasa data validate: 0 conflictos. F1 macro en test (partición de P05): Rasa/DIET 0.624 y SVM 0.648. F1 macro en validación cruzada agrupada por base_phrase_id (StratifiedGroupKFold): Rasa/DIET 0.655 y SVM 0.637; la validación cruzada nativa de Rasa (0.778) se descarta por fuga de paráfrasis entre entrenamiento y prueba. Smoke test con consultas nuevas: 44 de 54 intenciones correctas. Las pruebas unitarias de custom actions no aplican porque el chatbot no tiene acciones personalizadas. Al no cumplirse el criterio no se avanza al pre-piloto; las causas y las medidas adoptadas se registran en la Sección 5.

2.12 Pre-piloto y validación del instrumento (modificado en V1.2)

Modificación V1.2 (adoptada). El pre-piloto se divide en dos etapas, porque exigir $F1 \geq 0.75$ para entrar al pre-piloto era circular: el pre-piloto con personas es la vía más económica de obtener lenguaje real, y el Alfa de Cronbach del instrumento Likert no depende del desempeño del NLU. La decisión se tomó a partir de los resultados de P11.1 y antes de observar resultados del pre-piloto.

Etapla (a) — Recolección de lenguaje real y refinamiento (P11.2a). Se aplica el lote 1 (Sección 2.4.2) y, con sus resultados, se refina el chatbot (umbral de confianza, ajustes de corpus y de respuestas). No tiene umbral de F1 de entrada. Estado: ejecutado en lo esencial: lote 1 (más 1b y 1c) evaluado una vez (F1 0.687, G3 no cumplida) y lote 2 independiente evaluado una vez (F1 0.9072, G3 cumplida); refinamiento: 1 de 2 ciclos usados (Sección 5.8).

Etapla (b) — Pre-piloto formal (P11.2b). Un grupo de 5 a 15 personas (personal de la Plataforma de Atención y/o voluntarios), distinto e independiente de las 60 personas del piloto

exploratorio, prueba el chatbot desplegado en un entorno mínimo (asistente local en una laptop, widget web o canal de WhatsApp/Telegram) con un guion de 15 a 20 consultas (2 a 3 por categoría) y responde la encuesta de satisfacción; se calcula el Alfa de Cronbach (≥ 0.70 indica consistencia aceptable; si es menor, se ajustan los ítems). Estas personas no vuelven a participar en el piloto final. El pre-piloto ensaya el mismo procedimiento de la sesión asistida (Sección 2.4). Estado: pendiente de la etapa (a).

Criterio de salida del pre-piloto formal. Se pasa al piloto a escala completa (P12) solo si se cumplen de manera simultánea: $F1 \geq 0.75$ sobre el conjunto real retenido (validación y test del lote 1) y Alfa de Cronbach ≥ 0.70 . El umbral de 0.75, más permisivo que el 0.85 exigido en la evaluación final de OE2, se mantiene como condición de la etapa (b). Toda incidencia detectada se registra en `incident_log.csv` (P16) y se corrige antes de avanzar.

2.13 Evaluación del efecto en la atención ciudadana (OE1 → OE3 → OE4)

Todos los métodos de clasificación se evalúan bajo las mismas condiciones (mismas particiones y semillas) para fijar la arquitectura de OE2. El efecto del chatbot sobre la atención ciudadana se evalúa mediante el diseño pre-test/post-test de un solo grupo (Sección 2.4; piloto exploratorio $n = 60$, en una sola sesión asistida): el pre-test es el diagnóstico de OE1 (tiempos, limitaciones y satisfacción con la atención presencial) y el post-test es la medición de OE3 (tiempo de respuesta con el chatbot) y OE4 (satisfacción ciudadana), aplicados sobre los mismos sujetos. Antes de aplicar la prueba de hipótesis se verificará el supuesto de normalidad de las diferencias pre/post con la prueba de Shapiro-Wilk ($\alpha = 0.05$): si se cumple la normalidad, se aplica la prueba t de Student para muestras pareadas; si no se cumple, se aplica su alternativa no paramétrica, la prueba de Wilcoxon (rangos con signo), manteniendo el mismo nivel de significancia $\alpha = 0.05$.

2.14 Compuertas de avance (sin fechas)

Desde la V1.4 las etapas del piloto avanzan por criterios de avance y no por fechas. Cada compuerta se declara antes de ver resultados y no se modifica después. Si una compuerta no se cumple, esa etapa y las siguientes se presentan como planificadas: no se baja el umbral ni se repite una evaluación para forzar el paso.

- G1 — Lote 1 completo. El libro de transcripción indica «Listo para la Parte B»: al menos 15 participantes transcritos, ninguno sin consentimiento y cada intención con al menos 3 frases reales (meta de 4). Si falta, se sigue aplicando formularios con las personas de reserva.
- G2 — Parte B ejecutada. La ingesta termina sin errores bloqueantes y el tesista revisó el reporte de datos personales antes de subir cualquier archivo.
- G3 — Calidad con lenguaje real. Se permiten hasta 2 ciclos de refinamiento medidos sobre validación; se detienen antes si la mejora entre ciclos es menor a 0.02 de F1. Después, el conjunto de prueba real se evalúa una sola vez y se exige F1 macro de 0.75 o más.
- G4 — Respuestas verificadas. En la hoja de verificación del TUPA no quedan filas de prioridad Alta pendientes ni con alerta, y las aplicadas están confirmadas por el tesista. Las de prioridad Media sin verificar conservan la marca [Verificar] y se declaran como limitación.
- G5 — Modelo congelado. Se congela después de G3 y G4, porque las respuestas forman parte del modelo, y no cambia durante las sesiones. Se congelará el modelo medido en el lote 2 (sin re-entrenarlo con esas frases, porque un modelo nuevo no tendría medición).
- G6 — Pre-piloto. De 5 a 15 personas completan el procedimiento sin fallas técnicas que impidan medir, y el alfa de Cronbach es de 0.70 o más (con n pequeño se informa con la

advertencia correspondiente). Si falla, se corrige el instrumento y se repite una sola vez con otro grupo.

- G7 — Sesiones. La recolección se cierra al alcanzar 60 sesiones elegibles, o cuando el tesista declara el cierre con un mínimo de 30 (criterio de esta versión); con menos de 30 el piloto se presenta como demostración del procedimiento, sin análisis inferencial.

Estado de las compuertas a 8 de octubre de 2026 (datos reales): 4 de 7 cumplidas. G1 cumplida (lote 1 completo). G2 cumplida (Parte B ejecutada). G3 cumplida con el lote 2 (F1 macro 0.9072 frente a 0.75, evaluado una sola vez sobre 267 frases; con el test del lote 1 había sido 0.687 y no se repitió). G4 cumplida (28 filas confirmadas, 0 alertas, 0 de 44 respuestas con [Verificar]). G5 pendiente: se congelará el modelo medido en el lote 2. G6 pendiente. G7 pendiente. Las compuertas «Cumplida (Simulado)» de la Sección 5.7 no cuentan.

Datos simulados. Todo el flujo puede ejecutarse con datos simulados para demostrar el pipeline del curso. Sus resultados se rotulan «Simulado», no se mezclan con los archivos reales y no cumplen una compuerta real.

3. Protocolo experimental V1.7

El protocolo convierte la metodología en pasos concretos de ejecución. El flujo experimental general es: Corpus MPSR-Bot → auditoría → control de fuga → partición → preprocesamiento → entrenamiento (baseline y Rasa/DIET) → repeticiones → evaluación funcional → pruebas técnicas internas → recolección de lenguaje real y refinamiento → pre-piloto formal → piloto a escala completa → verificación de supuestos → análisis estadístico → reproducibilidad → incidencias.

Estados utilizados en la tabla y en la matriz: ejecutado (realizado con código y datos reales; el corpus es sintético salvo que se indique lo contrario), simulado (ejecutado con datos generados para demostrar el pipeline del curso; no son hallazgos de campo), planificado (definido y con materiales listos, aún no ejecutado) y adoptado (decisión de diseño vigente). Los pasos que muestran «Simulado (ejecutado en la demostración)» se ejecutaron además con datos simulados en la demostración de la Sección 5.7; su estado real es el que figura antes del punto y coma.

ID	Paso	Descripción	Estado
P01	Diagnóstico de canales actuales (OE1)	Relevar, mediante autoreporte retrospectivo, la experiencia de los últimos 12 meses con la atención presencial (TramiFácil es uso interno del personal; no se reporta como canal ciudadano). V1.3: la línea base se recoge como Parte 1 de la sesión asistida (mismo contenido que la Ficha de Diagnóstico P01), en la misma visita en que la persona prueba el chatbot; sin WhatsApp ni seguimiento. Reclutamiento: estudios contables/jurídicos de Juliaca (muestreo por cuotas, ver Sección 2.4). Tamaño: n = 60 sesiones elegibles (piloto exploratorio; el n = 120 de la V1.2 queda como valor planificado). La línea base simulada de 120 respuestas solo demuestra el pipeline; no es trabajo de campo real.	Simulado; real planificado (sesión asistida)
P02	Adquisición y registro del corpus (OE2)	Registrar fuente (construcción manual y plantillas coloquiales, pendiente de contrastar con el TUPA oficial), fecha/versión, n° de utterances, intenciones y categorías. Crear corpus_metadata.csv con utterance_id, intent, category, source, base_phrase_id y split. V1.2: el lote 1 de frases reales (Sección 2.4.2) se registra como fuente separada.	Ejecutado (sintético); lote 1, 1b y 1c ejecutados; Simulado (ejecutado en la demostración)
P03	Auditoría inicial (OE2)	Verificar duplicados (similitud de Jaccard o Levenshtein normalizada ≥ 0.90 dentro de la misma intención), utterances ambiguas, distribución por intención/categoría y desbalance entre las 54 intenciones. Evidencias: corpus_audit.csv y reporte de auditoría.	Ejecutado
P04	Control de fuga por paráfrasis (OE2)	Agrupar variantes de una misma frase base (umbral de similitud ≥ 0.90) con base_phrase_id. Ningún grupo podrá aparecer repartido entre train, validation y test.	Ejecutado
P05	División de datos (OE2)	Aplicar partición 70/15/15 con semilla registrada (42); agrupar por base_phrase_id. Registrar en dataset_split.csv. El test permanece aislado hasta la evaluación final. Resultado ejecutado en la V1.1 (corpus v2): $486/81/81 = 75 / 12.5 / 12.5 \%$ (con 4 grupos por intención, 3 van a entrenamiento y el cuarto alterna entre validación y test; el 70/15/15 era el objetivo nominal). El corpus v3 agrega 60 frases solo a entrenamiento. Modificación V1.2: entrenamiento = frases sintéticas; validación y test = frases reales del lote 1, con las 54 intenciones en las tres particiones (la partición V1.1 deja 27 de 54 intenciones en test).	V1.1 ejecutado; V1.2 ejecutada con el lote 1 real (entrenamiento 707 sintéticas; validación 71 y test 114 reales); Simulado (ejecutado en la demostración)
P06	Preprocesamiento NLU (OE2)	Normalización de texto (minúsculas, tildes, jerga local), tokenización y featurización (TF-IDF para baseline; CountVectors/embeddings para Rasa).	Ejecutado

ID	Paso	Descripción	Estado
P07	Experimento baseline (ML) (OE2)	Pipeline: utterance → TF-IDF (max_features=5000, ngram_range=(1,2)) → SVM (kernel lineal, C∈{0.1,1,10}) o regresión logística (C=1.0, max_iter=1000) → intención. Seed=42 en todas las corridas; se conserva el C con mejor F1 en validación.	Ejecutado
P08	Experimento Rasa NLU / DIET (OE2)	Pipeline Rasa: WhitespaceTokenizer + CountVectorsFeaturizer (n-gramas de caracteres 1–4) + DIETClassifier. Grilla fijada: epochs∈{100,150,200}, batch_size∈{64,128}, embedding_dimension∈{20,50}, learning_rate=0.001, constrain_similarities=true. Seed=42; se conserva la combinación con mejor F1 en validación (early stopping por evaluate_on_number_of_examples).	Ejecutado
P09	Gestión del diálogo (OE2)	Documentar stories, rules, forms y custom actions que completan la conversación con el ciudadano, usando el TUPA y la información institucional de la MPSR. Estado: 54 de 54 respuestas redactadas en domain.yml; tras contrastar con el TUPA y los canales oficiales (08/10/2026), ninguna de las 44 de trámites conserva la marca [Verificar]. V1.2: se agrega el umbral de confianza (Sección 2.10).	Respuestas ejecutadas; umbral ejecutado; Simulado (ejecutado en la demostración)
P10	Repeticiones (OE2)	Ejecutar múltiples corridas independientes del baseline y de Rasa/DIET con semillas predefinidas (10, 20, 30, 40, 50) para estimar variabilidad.	Ejecutado
P11	Métricas de clasificación (OE2)	Calcular Accuracy, Precision macro, Recall macro, F1 macro y Balanced Accuracy, además de la matriz de confusión por intención, para cada repetición. Se fija la arquitectura final con F1 ≥ 0.85. V1.2: el reporte sobre el conjunto real incluye IC95 % bootstrap y prueba pareada (McNemar) entre Rasa/DIET y el baseline.	Ejecutado (sintético); reporte real planificado; Simulado (ejecutado en la demostración)
P11.1	Pruebas técnicas internas (OE2)	Sin involucrar personas externas: rasa data validate (conflictos), validación cruzada del NLU agrupada por base_phrase_id (la nativa de Rasa se descarta por fuga de paráfrasis) y smoke test de las 54 intenciones con consultas nuevas; las pruebas unitarias de custom actions no aplican (no hay acciones personalizadas). Criterio de salida: 0 conflictos, F1 ≥ 0.75 y 54/54 intenciones sin error. Resultado: 0 conflictos; F1 macro 0.624–0.655; 44/54. Criterio no cumplido. Ver Sección 2.11.	Ejecutado (criterio no cumplido)
P11.2a	Recolección de lenguaje real y refinamiento (OE2–OE4)	Aplicar el lote 1 de frases reales (Sección 2.4.2), evaluar en la validación y el test reales y refinar el chatbot (umbral de confianza, ajustes de corpus y de respuestas). No tiene umbral de F1 de entrada. Ver Sección 2.12.	Ejecutado: lote 1 (F1 0.687, G3 no cumplida) y lote 2 independiente (F1 0.9072, G3 cumplida), cada test evaluado una sola vez; refinamiento 1 de 2 ciclos; Simulado (ejecutado en la demostración) — sin refinamiento
P11.2b	Pre-piloto formal (OE2–OE4)	Probar el chatbot con 5–15 personas ajenas a la muestra final (guion de 15–20 consultas, 2–3 por categoría), aplicarles la encuesta de satisfacción y calcular el Alfa de Cronbach. Criterio de salida: F1 ≥ 0.75 sobre el conjunto real retenido y Alfa ≥ 0.70. Ver Sección 2.12.	Pendiente (depende de P11.2a)
P12	Despliegue piloto y medición de tiempos (OE3)	Una vez superado el pre-piloto formal (P11.2b) y con el modelo congelado, ejecutar las sesiones asistidas: en la misma visita en que la persona responde su línea base (P01), prueba el chatbot (asistente local o canal propio, sin integración con la MPSR) con 3 tarjetas de situación. El aplicador mide el tiempo hasta una respuesta útil (corte a los 180 s o a los 3 mensajes) y lo compara con la línea base recordada de la misma persona (medición pareada).	Planificado (sesión asistida, n = 60); Simulado (ejecutado en la demostración)

ID	Paso	Descripción	Estado
P13	Encuesta de satisfacción (OE4)	En la misma sesión, la persona responde la encuesta de satisfacción Likert de 5 puntos (9 ítems; el ítem 9 empareja con la satisfacción previa P10) y una pregunta complementaria con el tiempo presencial estimado para la consulta 1. Inclusión: sesión elegible y completa (trámite presencial en los últimos 12 meses); exclusión: participantes de P11.2b. n = 60 (piloto exploratorio).	Planificado (en la misma sesión); Simulado (ejecutado en la demostración)
P14	Análisis estadístico (OE3–OE4)	Verificar normalidad de las diferencias pre/post (mismos sujetos) con Shapiro-Wilk ($\alpha=0.05$). Si se cumple, aplicar prueba t de Student pareada; si no, aplicar la alternativa no paramétrica Wilcoxon (rangos con signo). Formular H0/H1 y aplicar el criterio de decisión con $\alpha=0.05$.	Simulado (demostración del pipeline)
P15	Reproducibilidad	Conservar código, configuraciones, semillas, particiones, modelos, predicciones, métricas, logs y un README con el orden de ejecución.	Ejecutado
P16	Registro de incidencias	Documentar fecha, experimento, incidencia, decisión adoptada y justificación de toda desviación del protocolo (p. ej. reetiquetado, falla de despliegue, ajuste de ítems tras el pre-piloto).	Ejecutado (bitácora en incident_log.csv)

3.1 Regla fundamental de aislamiento del test

El conjunto de prueba no se utilizará para seleccionar características, ajustar hiperparámetros, elegir la arquitectura, decidir el número de épocas ni escoger el modelo final (OE2). De igual forma, el post-test de OE3/OE4 no se anticipa ni se contamina con decisiones tomadas durante el diagnóstico de OE1.

3.2 Pregunta de control

Si se solicita demostrar de dónde salió un F1-Score reportado en la tesis, debe poder identificarse: el corpus y su versión, la partición, el código, la configuración, la semilla, las predicciones y el experimento (ID) que lo produjeron. Si la respuesta es sí, existe trazabilidad experimental.

4. Matriz de trazabilidad técnica

Lógica de trazabilidad: Objetivo → actividad → datos → procedimiento → configuración → evidencia → métrica → análisis → resultado. Ejemplo: OE3 → medir tiempo de respuesta con el chatbot → registros post-test (T09) → protocolo P12 → mismas categorías que la línea base → registros de tiempo → % de reducción → evidencia de mejora en la atención ciudadana.

La columna Estado indica si cada fila está ejecutada, simulada, planificada o pendiente (definiciones en la Sección 3). Las filas T03.1, T07.2a y T07.2b son nuevas en la V1.2; T01 y T08–T11 se modifican en la V1.3 (piloto en sesión asistida).

ID	Objetivo específico	Actividad	Entrada / datos	Procedimiento	Configuración / control	Evidencia verificable	Métrica / criterio	Análisis / resultado esperado	Estado
T01	OE1. Diagnosticar la situación actual de los canales de atención.	Relevar, vía autoreporte, tiempos y limitaciones de la atención presencial (TramiFácil es uso interno).	Parte 1 de la sesión asistida (mismo contenido que la Ficha P01); 60 sesiones elegibles reclutadas en estudios contables/jurídicos.	Medición retrospectiva de tiempos y cuellos de botella, en la misma visita en que se prueba el chatbot; sin WhatsApp ni seguimiento.	Muestra por cuotas (9 categorías), n = 60 (piloto exploratorio; la V1.2 planificaba 120).	Registro de sesiones (Registro_Sesiones_Pilot o) y hojas originales.	Tiempo promedio reportado (línea base recordada).	Línea base recordada de cada persona, comparada con su medición de T09 en la misma sesión.	Simulado; real planificado
T02	OE1	Evaluar capacidades y limitaciones de TramiFácil.	Plataforma TramiFácil.	Análisis funcional: qué resuelve y qué no resuelve TramiFácil.	Criterios de interactividad y cobertura de trámites.	Ficha de evaluación de TramiFácil.	Nº de limitaciones documentadas.	Justificación técnica de la necesidad del chatbot.	Planificado
T03	OE2. Construir el Corpus MPSR-Bot.	Registrar el corpus.	Construcción manual y plantillas coloquiales (pendiente de contrastar con el TUPA oficial).	Crear inventario e identificadores de utterance.	Fuente y versión registradas por intención/categoría.	corpus_metadata.csv (v3, 708 frases; la v2 en corpus/historico/)	N.º utterances, intenciones (54) y categorías (9).	Corpus identificado y documentado.	Ejecutado (sintético)
T03.1	OE2	Recolectar el lote 1 de frases reales.	15–25 adultos de Juliaca; 56 situaciones en 5 formularios (A–E); consentimiento informado.	Cada participante escribe su frase para unas 11 situaciones; transcripción literal; revisión de la etiqueta frase por frase.	Muestra de conveniencia; frases no usadas para entrenar; anonimato (sin nombres ni contacto).	Respuestas transcritas, seguimiento por participante (plantilla v3), hojas originales y revisión de etiquetas.	≥ 3 frases reales por intención; % de etiquetas modificadas en la revisión.	Conjunto de lenguaje real para validación y test (V1.2).	Ejecutado (lotes 1, 1b y 1c); Simulado (ejecutado en la demostración)
T04	OE2	Auditar calidad del corpus.	Corpus registrado.	Detectar duplicados, ambigüedad y desbalance.	Criterios de inclusión/exclusión definidos.	corpus_audit.csv + reporte	Distribución e integridad por intención.	Caracterización y calidad del corpus.	Ejecutado

ID	Objetivo específico	Actividad	Entrada / datos	Procedimiento	Configuración / control	Evidencia verificable	Métrica / criterio	Análisis / resultado esperado	Estado
T05	OE2	Controlar fuga por paráfrasis y particionar.	Utterances y frase base.	Asignar base_phrase_id; separar train/val/test.	Objetivo 70/15/15; V1.1 ejecutada (corpus v2): 486/81/81 = 75/12.5/12.5 (3 de 4 grupos a entrenamiento); el corpus v3 agrega 60 frases solo a entrenamiento; seed = 42; agrupado por frase base. V1.2: entrenamiento sintético; validación y test reales.	dataset_split.csv (vigente, sobre el corpus v3); la V1.1 en corpus/historico/dataset_split_v2_648.csv; corpus/v3_real/dataset_split_v3.csv (V1.2, planificado)	Solapamiento entre particiones = 0. + 54/54 intenciones en cada partición (V1.2).	Corpus sin fuga, partición reproducible.	V1.1 ejecutado; V1.2 ejecutada; Simulado (ejecutado en la demostración)
T06	OE2	Implementar y comparar baseline (ML) vs. Rasa/DIET.	Utterances preprocesadas.	Entrenar TF-IDF+SVM y Rasa NLU/DIET bajo las mismas condiciones.	Hiperparámetros y semillas registrados; test aislado.	logs/BASE-*, logs/RASA-*, logs/stats_modelos.txt	F1 macro (meta $\geq$ 0.85), Balanced Accuracy, Precision, Recall. Sintético (corpus v3): Rasa 0.624; SVM 0.648 (test).	DIET no supera al baseline en el corpus sintético; se repite sobre el conjunto real con IC95 % y McNemar (V1.2).	Ejecutado (sintético); real planificado; Simulado (ejecutado en la demostración)
T07	OE2	Construir la gestión del diálogo.	Intenciones y entidades reconocidas + TUPA/información institucional.	Reglas intención → respuesta fija (sin custom actions, forms ni slots). V1.2: umbral de confianza (FallbackClassifier).	Cobertura de las 9 categorías de intención.	domain.yml, rules.yml, evidencias/p09_domain/	54/54 respuestas; 40 de 44 de trámites marcadas [Verificar] al inicio (a 08/10/2026, 0 de 44).	Arquitectura del chatbot implementada.	Respuestas ejecutadas; umbral planificado; Simulado (ejecutado en la demostración)
T07.1	OE2	Ejecutar pruebas técnicas internas.	Chatbot funcional (T07): NLU + gestión del diálogo.	rasa data validate; validación cruzada agrupada; smoke test de las 54 intenciones (las pruebas unitarias de actions no aplican).	0 conflictos; F1 $\geq$ 0.75; 54/54 intenciones sin error.	evidencias/p11_1_pruebas/; REPORTE_REEVALUACION.md	Conflictos, F1 (test y validación cruzada agrupada), intenciones correctas.	Criterio no cumplido: 0 conflictos; F1 0.624–0.655; 44/54. No se avanza al pre-piloto.	Ejecutado (criterio no cumplido)
T07.2a	OE2-OE4	Refinar el chatbot con lenguaje real (P11.2a).	Resultados de T03.1 y partición V1.2 de T05.	Evaluar en validación real; elegir el umbral de confianza; ajustar corpus y respuestas.	Sin umbral de F1 de entrada; umbral elegido con criterio fijado de antemano (aciertos – 2 × errores).	Reporte de evaluación real; tabla de umbrales.	F1 macro con IC95 %; cobertura y precisión del umbral.	Chatbot refinado con evidencia sobre lenguaje real.	Ejecutado (lote 1 y lote 2; 1 de 2 ciclos de refinamiento); Simulado (ejecutado en la demostración) — sin refinamiento
T07.2b	OE2-OE4	Ejecutar el pre-piloto formal y validar el instrumento (P11.2b).	Chatbot refinado (T07.2a) + encuesta de satisfacción.	Probar con 5–15 personas ajenas a la muestra final (guion de 15–20 consultas) y aplicarles la encuesta.	F1 $\geq$ 0.75 sobre el conjunto real retenido; Alfa de Cronbach $\geq$ 0.70.	Resultados del guion + respuestas de la encuesta piloto.	F1 sobre el conjunto real y Alfa de Cronbach del instrumento.	Decisión de avanzar al piloto completo o corregir modelo/instrumento.	Pendiente (depende de T07.2a)
T08	OE3. Medir la reducción del tiempo de respuesta.	Preparar el asistente para las sesiones (asistente local o canal propio) con el modelo congelado.	Chatbot funcional (OE2), validado en T07.1 y T07.2b.	Congelar el modelo (nombre, versión y fecha) y levantar el asistente en la laptop del aplicador.	Modelo sin cambios durante las sesiones.	Registro del modelo congelado (hoja Parametros) y bitácora de incidencias técnicas.	Disponibilidad del asistente durante las sesiones.	Asistente operativo y estable para la medición.	Planificado

ID	Objetivo específico	Actividad	Entrada / datos	Procedimiento	Configuración / control	Evidencia verificable	Métrica / criterio	Análisis / resultado esperado	Estado
T09	OE3	Medir tiempo de respuesta con el chatbot.	Consultas de las mismas personas de T01, hechas en la misma sesión con 3 tarjetas de situación.	Registrar el tiempo hasta una respuesta útil por consulta (cronómetro del aplicador; corte a los 180 s o a los 3 mensajes).	Mismas categorías de trámite y mismos sujetos que T01.	Registros de tiempo (post, misma sesión), pareados con T01.	Tiempo promedio de respuesta (post).	Dato post-test pareado para la comparación.	Simulado; real planificado
T10	OE3	Comparar tiempos pre/post (mismo sujeto).	Línea base (T01) + tiempos del chatbot (T09), mismos sujetos.	Calcular diferencia y porcentaje de reducción del tiempo de respuesta por sujeto.	Comparación pareada; mismo criterio de medición en ambos momentos.	Tabla comparativa pre/post pareada.	% de reducción de tiempo (meta $\geq 60\%$).	Evidencia cuantitativa de mejora en el tiempo de atención.	Simulado; real planificado
T11	OE4. Evaluar el nivel de satisfacción ciudadana.	Aplicar encuesta de usabilidad (post-test).	Mismas personas de T01 que usaron el chatbot en la sesión (excluye participantes de T07.2b).	Encuesta con escala Likert de 5 puntos (9 ítems) en la misma sesión.	n = 60 (piloto exploratorio); la V1.2 planificaba 120 (Vargas Ríos, 2022).	Base de datos de encuesta (Registro de sesiones), pareada con T01.	Puntaje Likert promedio (meta $\geq 4.0/5.0$).	Nivel de satisfacción post documentado, comparable a la línea base de T01.	Simulado; real planificado
T12	OE4	Analizar errores y percepción negativa.	Predicciones del chatbot + respuestas de la encuesta.	Identificar intenciones confundidas y comentarios críticos.	Criterios uniformes de análisis.	Matrices de confusión + comentarios de encuesta.	FP/FN por intención; ítems Likert bajos.	Explicación de patrones de error e insatisfacción.	Parcial (sintético ejecutado; encuesta planificada)
T13	OE1-OE4	Contrastar la hipótesis estadísticamente.	Datos pre/post de tiempo (T01, T10) y satisfacción (T11) — mismos sujetos.	Verificar normalidad de las diferencias (Shapiro-Wilk) y aplicar prueba t de Student pareada o, en su defecto, Wilcoxon.	$\alpha = 0.05$; H0/H1 formales.	Script + tabla estadística.	p-value y decisión sobre H0.	Evidencia cuantitativa del efecto del chatbot en la atención ciudadana (mismo sujeto, antes/después).	Simulado; real planificado
T14	OE1-OE4	Garantizar reproducibilidad.	Todos los experimentos.	Integrar código, configuraciones, seeds, logs y resultados.	Versionado del protocolo y del software.	Repositorio + README.md	Experimento reproducible y rastreable.	Trazabilidad completa objetivo → resultado.	Ejecutado
T15	OE1-OE4	Registrar incidencias y desviaciones del protocolo.	Cualquier desviación durante P01–P14 (falla de despliegue, reetiquetado, corte de energía, ajuste de ítems tras T07.2b, etc.).	Documentar fecha, experimento, incidencia, decisión y justificación.	Ninguna incidencia se resuelve u omite silenciosamente.	Bitácora de incidencias (incident_log.csv).	N.º de incidencias registradas y resueltas.	Historial de desviaciones justificado y auditable.	Ejecutado (bitácora en incident_log.csv)

4.1 Cómo interpretar la matriz

Si en la tesis se reporta un F1-Score, un porcentaje de reducción de tiempo o un valor de satisfacción, debe poder identificarse: el objetivo específico (OE1–OE4) al que corresponde, el corpus o registro de origen, la partición o muestra, el código o instrumento, la configuración, la semilla (cuando aplique), las predicciones/registros y el ID de experimento de esta matriz que lo produjo.

5. Registro de modificaciones y control de versiones

Esta sección documenta, conforme al criterio de la docente, los errores encontrados, las medidas tomadas y su estado. La presentación del trabajo corresponde a la matriz de la Sección 4 con las modificaciones aquí registradas.

5.1 Control de versiones

Versión	Cambio principal	Motivo
V1.0	Protocolo inicial: planteamiento, metodología, protocolo y matriz adaptados del modelo de la docente.	Entrega inicial de Tesis II.
V1.1	Correcciones de la revisión por pares (Ficha 1): hiperparámetros fijados, muestreo y tamaño de muestra, verificación de normalidad, fila T15 y pasos P11.1 y P11.2.	Observaciones de la Ficha 1, respondidas en la Ficha 2.
V1.2 (3 oct. 2026)	Lote 1 de frases reales, partición V1.2, umbral de confianza, P11.2 en dos etapas, columna de estado en protocolo y matriz, y correcciones de consistencia (54 intenciones; TramiFácil de uso interno).	Criterio de salida de P11.1 no cumplido, defecto de partición y corpus sintético.
V1.3 (3 oct. 2026)	Piloto exploratorio de 60 personas en una sola sesión asistida (línea base recordada, prueba del asistente con 3 tarjetas y encuesta de 9 ítems); formulario de sesión y registro de sesiones; modelo congelado antes de las sesiones.	Plazo del curso menor a 2 semanas y objetivo de mostrar viabilidad; evita el recontacto y el abandono.
V1.4 (5 oct. 2026)	Las etapas del piloto avanzan por compuertas de criterio (Sección 2.14) y no por fechas. Todo el flujo puede ejecutarse con datos simulados, rotulados «Simulado».	El tesista prefiere medir el avance por resultados; evita fijar fechas que no controla (reclutamiento, verificación del TUPA).
V1.5 (6 oct. 2026)	Se agrega la demostración simulada completa del flujo (Sección 5.7), con todos sus resultados rotulados «Simulado», y los pasos P02, P05, P09, P11, P11.2a, P12 y P13 muestran además «Simulado (ejecutado en la demostración)». No cambia el diseño ni los estados reales.	Mostrar que el flujo funciona de extremo a extremo antes de contar con datos reales; sus resultados no son hallazgos de campo y no cumplen ninguna compuerta real.
V1.6 (8 oct. 2026)	Se registran los resultados reales: lote 1, 1b y 1c (32 participantes, 185 frases activas), partición V1.2 ejecutada, F1 macro del test real 0.687 (G3 no cumplida), G4 cumplida con la verificación del TUPA y de los canales oficiales, desviación de perfil (P08, P24, P25), limitación de reparto y hallazgo sobre «gracias». Se planifica un lote 2 con prueba independiente (Sección 5.8). No cambia el diseño del piloto.	Existen ya datos reales; el protocolo debe reflejar su estado, y el resultado de G3 exige declarar el siguiente paso antes de medirlo.
V1.7 (8 oct. 2026)	Se registran el lote 2 y la medición única de G3: F1 macro 0.9072 sobre 267 frases de 25 participantes nuevos (IC95 % por participantes 0.852–0.939), G3 cumplida y 4 de 7 compuertas reales cumplidas; G4 sin respuestas con [Verificar] (0 de 44); limitaciones del diseño (mismas 56 situaciones, una sola revisora, no comparable con el lote 1). No cambia el diseño del piloto.	Existe una medición nueva e independiente; el protocolo debe reflejar su estado real y sus límites antes de pasar al pre-piloto.

5.2 Errores detectados y causas

- Corpus sintético. Ampliarlo con frases sintéticas nuevas no mejoró la generalización (4 aciertos ganados y 7 perdidos en el smoke test: diferencia compatible con ruido, McNemar $p \approx 0.55$) y generó rebote entre intenciones vecinas (horario_mesa_partes absorbió predicciones de requisitos_mesa_partes: exactitud $0.87 \rightarrow 0.53$).
- Defecto de partición (P05). Cada intención tiene un solo grupo retenido, asignado alternadamente a validación o a test. El test mide 27 de las 54 intenciones (3 frases cada una) y la validación las otras 27: sus F1 no son comparables y la grilla se seleccionó con la mitad de las intenciones.
- Muestras pequeñas y sin ventaja de DIET. Con 3 frases por intención el F1 macro es muy variable; Rasa/DIET y TF-IDF + SVM resultan indistinguibles en este corpus.
- Caso crítico corregido. Una consulta de licencia (“abrir un restaurante”) se clasificó como fuera_de_alcance con 0.81 de confianza: esa palabra aparecía una sola vez en el entrenamiento, dentro de un ejemplo de fuera_de_alcance.

5.3 Medidas ya ejecutadas

Medida ejecutada	Resultado	Evidencia
Validación cruzada agrupada por base_phrase_id (StratifiedGroupKFold) en lugar de la nativa de Rasa	Nativa 0.778 (inflada por fuga) frente a 0.655 (Rasa) y 0.637 (SVM) agrupada	evidencias/p11_1_pruebas/
Ampliación del corpus (60 frases, 20 grupos, 9 intenciones) y corrección de la causa del falso fuera_de_alcance	Corrigió las 8 fallas; sin mejora global (F1 test 0.633 (corpus v2) $\rightarrow$ 0.624 (corpus v3))	REPORTE_REEVALUACION.md; logs/v2_corpus648/
Respuestas del domain.yml completas (P09) y marcadas con [Verificar] las no contrastadas con el TUPA real	54/54 respuestas; 40 de 44 de trámites marcadas al inicio (a 08/10/2026 quedan 0 de 44); rasa data validate sin conflictos	evidencias/p09_domain/
Preparación de la Parte B: scripts de ingesta, partición V1.2, evaluación real, umbral de confianza y conciliación con el seguimiento	Pruebas de humo con datos falsos (simuladas): 59/59 y 22/22; el flujo real espera el lote 1	evidencias/v3_real/

Medida ejecutada	Resultado	Evidencia
Verificación de cifras y referencias del protocolo V1.2 y de la nota contra el repositorio	37 afirmaciones recalculadas: 30 coincidían y 5 diferían (corregidas en esta versión)	evidencias/v3_real/verificacion_referencias.md; docs/ERRATAS_protocolo_V1.2.md
Materiales del piloto exploratorio: formulario de sesión asistida (guía, paquete por persona y 56 tarjetas) y registro de sesiones con fórmulas	Fórmulas del registro verificadas con datos de prueba (simulados): 16 resultados coinciden con un cálculo independiente	docs/piloto/
Demostración simulada completa del flujo (ingesta, revisión de etiquetas, partición, evaluación en validación y test, umbral, modelo de demostración, análisis de sesiones y tablero)	SIMULADO: 10 etapas ejecutadas, sin ninguna cifra de campo. Compuertas cumplidas con datos reales: 0 de 7 (3 «Cumplida (Simulado)»). Aislamiento: 55 archivos reales comprobados con SHA-256, ninguno cambió	evidencias/simulado_demostracion/20261005_demostracion/; Sección 5.7
Lote 1 real (1, 1b y 1c), partición V1.2 y evaluación única en el test real	32 participantes; 185 frases activas (71 validación, 114 test); entrenamiento 707 sintéticas; F1 macro test 0.687 (criterio 0.75 no cumplido); IC95 % 0.570–0.707; 0 ciclos de refinamiento	logs/v3_real/; evidencias en el repositorio (carpeta privada fuera de Git)
Verificación de las respuestas contra el TUPA y los canales oficiales y aplicación a domain.yml	28 filas confirmadas por el tesista; 0 alertas; 0 de 44 respuestas con [Verificar]; humo de respuestas 54/54 sin problemas	docs/tupa/Verificacion_TUPA_v10_4.xlsx; logs/avance/aplicar_respuestas_aplicado2.md
Lote 2 real (P33–P57), partición del lote 2 y evaluación única en el test	25 participantes; 280 frases, 13 excluidas por duplicado con el entrenamiento, 267 en test; F1 macro 0.9072 (criterio 0.75 cumplido); IC95 % por participantes 0.852–0.939; cobertura 92.9 %, precisión de lo respondido 95.6 %	logs/avance/eval_lote2_notas.md; logs/avance/particion_lote2_cifras.md; logs/v3_real/ (carpeta privada fuera de Git)

5.4 Modificaciones al protocolo y a la matriz

Paso / fila	Modificación (V1.1 → V1.2)	Justificación	Estado
P02 / T03.1	Lote 1 de frases reales: 15 a 25 adultos de Juliaca, unas 11 situaciones sin palabras clave; anónimo, con consentimiento; muestra de conveniencia.	El corpus sintético no representa el habla real.	Ejecutado
P05 / T05	Entrenamiento = frases sintéticas; validación y test = frases reales, con las 54 intenciones en las tres particiones.	Corrige la cobertura (27 de 54 intenciones en test) y mide la generalización real.	Ejecutado
P09 / T07	Umbral de confianza (FallbackClassifier) elegido en la validación real con criterio fijado de antemano: aciertos – 2 × errores con respuesta.	Evita respuestas erróneas con alta confianza.	Ejecutado
P11.2 / T07.2a–b	Dividir en (a) lenguaje real y refinamiento, sin umbral de F1, y (b) pre-piloto formal con Alfa ≥ 0.70 y F1 ≥ 0.75 sobre el conjunto real retenido.	Exigir F1 ≥ 0.75 para entrar era circular; el Alfa no depende del NLU. Decidido antes de observar resultados del pre-piloto.	Adoptado

Paso / fila	Modificación (V1.1 → V1.2)	Justificación	Estado
P11 / T06	Comparar DIET y SVM con IC95 % bootstrap y McNemar sobre el conjunto real.	Evitar sobreinterpretar diferencias pequeñas.	Parcial
P01, P12–P13 / T01, T08–T11	Piloto exploratorio de 60 personas en una sola sesión asistida: línea base recordada, prueba del asistente con 3 tarjetas (tiempo medido por el aplicador) y encuesta de 9 ítems en la misma visita. Reemplaza el diseño de dos visitas con 120 personas y WhatsApp. Las etapas avanzan por compuertas de criterio, no por fechas (Sección 2.14): si una compuerta no se cumple, el piloto se presenta como planificado desde esa etapa.	Plazo menor a 2 semanas y objetivo de mostrar viabilidad; evita el seguimiento y el abandono. Decidido antes de recoger datos del piloto.	Adoptado
Sección 2.14 / G1–G7	Siete compuertas de avance (lote 1 completo, Parte B ejecutada, F1 real, respuestas verificadas, modelo congelado, pre-piloto y sesiones) con criterios declarados antes de ver resultados y sin fechas.	Mide el avance por resultados y evita fijar plazos que el tesista no controla.	Adoptado
Demostración simulada completa / P02–P14	Ejecución del flujo de extremo a extremo con datos simulados, rotulada «Simulado» y escrita solo en evidencias/simulado_demostracion/. Los pasos ejecutados en ella se marcan «Simulado (ejecutado en la demostración)» sin cambiar su estado real.	Demostrar el pipeline del curso sin mezclar datos simulados con reales; sus resultados no son hallazgos de campo ni cumplen compuertas reales.	Simulado
Lote 2 / G3 (V1.6)	Conjunto de prueba nuevo e independiente (personas distintas); el entrenamiento incorpora las frases reales del lote 1 (modifica la regla V1.2 de no entrenar con frases reales); G3 se mide una sola vez sobre el lote 2.	G3 no se cumplió con el test del lote 1 (0.687); no se repite esa evaluación ni se baja el umbral. Decidido antes de medir.	Ejecutado (G3 cumplida: F1 macro 0.9072, V1.7)

5.5 Observaciones de consistencia

- El corpus tiene 54 intenciones (44 de trámites y 10 conversacionales); la formulación de Tesis I menciona 50. Se documenta como diferencia de alcance.
- OE1 y OE3, tal como se aprobaron en Tesis I, nombran a TramiFácil como canal de comparación. TramiFácil es una herramienta de uso interno del personal de la MPSR y los ciudadanos no la usan directamente; por eso la línea base ciudadana se mide solo para la atención presencial y TramiFácil se evalúa de forma documental (T02). Se declara como ajuste de alcance.

- La línea base de P01 y el post-test de P12–P14 se simularon para demostrar el pipeline: no son hallazgos de campo.
- En la sesión asistida la línea base es recordada y el tiempo con el asistente se mide en la misma visita: hay sesgo de recuerdo y de novedad, y la línea base mide el trámite mientras OE3 habla de consultas. Se declara como limitación.
- El ítem 9 de satisfacción (pareado con P10) y la pregunta complementaria de tiempo presencial estimado para la consulta 1 son adiciones de la V1.3; el ítem de preferencia ya no menciona TramiFácil.
- Los archivos corpus_metadata.csv y dataset_split.csv vigentes corresponden al corpus v3 (708 frases); las versiones v1 y v2 y la partición V1.1 original (corpus v2) están en corpus/historico/. Los resultados de P11.1 se obtuvieron con el corpus v3. La partición V1.1 ejecutada (corpus v2) es $486/81/81 = 75/12.5/12.5$, no el 70/15/15 nominal.
- Hallazgo sobre «gracias». Las personas usan «gracias» tanto para agradecer como para despedirse. Se reescribieron las respuestas de agradecimiento y despedida para que funcionen con ambas lecturas, y la confusión despedida ↔ agradecimiento se reporta aparte como esperada.
- Criterio de trámite reciente. Haber realizado un trámite en los últimos 12 meses (variable tramite_12m) no es criterio de inclusión: se registra solo como observación (P26, P27 y P29–P32 respondieron «No») y no constituye desviación.

5.6 Criterio de presentación y limitaciones

Cada modificación se presenta con su estado real (ejecutado, simulado, planificado o adoptado). Si alguna no se ejecuta dentro del curso, se presenta como planificada, con su justificación, y no como ejecutada.

- El entrenamiento combina frases sintéticas y reales del lote 1; el test del lote 2 usa lenguaje real de personas distintas, pero sobre las mismas 56 situaciones, con una sola revisora de etiquetas y 4 a 5 frases por intención. El F1 real tiene incertidumbre y no se extrapola a situaciones nuevas (Sección 5.8).
- Limitación de reparto. Cada frase es su propio grupo de partición; 28 de 31 participantes y 52 de 56 situaciones tienen frases tanto en validación como en test. Las particiones no son independientes por participante ni por situación, y la muestra es pequeña y de conveniencia: el F1 real tiene alta varianza.
- Las respuestas del chatbot (domain.yml) se contrastaron con el TUPA vigente y los canales oficiales de la MPSR (28 filas confirmadas el 08/10/2026); no queda ninguna con [Verificar] (constancia_domiciliaria: costo y plazo confirmados por el tesista).
- Desviación del perfil de participantes. Tres participantes (P08, P24 y P25) indicaron no vivir en Juliaca, lo que se aparta del criterio «adultos de Juliaca»: 3 de 32 participantes (9.4 %) y 20 de 186 frases (10.8 %). Se conservan en el corpus y se declara la desviación; la lectura de los resultados debe considerarla.
- El piloto exploratorio de $n = 60$ tiene un margen de error de aproximadamente 11.7 % ($N \approx 400$, 95 %) y potencia del 80 % para efectos de $d \approx 0.37$ o mayores: muestra viabilidad, no confirma hipótesis.
- Todo el flujo del curso puede ejecutarse con datos simulados, rotulados «Simulado». Un resultado simulado nunca cuenta como evidencia de campo ni cumple una compuerta real.

- La demostración simulada completa (Sección 5.7) usa frases generadas, consultas copiadas de las tarjetas, un predictor simulado y una revisión de etiquetas automática; sus cifras no miden lenguaje real ni el modelo, y no cuentan como evidencia de campo.

5.7 Demostración simulada completa del flujo (SIMULADO)

ESTADO: SIMULADO — datos de prueba; no son hallazgos de campo. Todo lo de este informe es SIMULADO. Ejecución 20261005_demostracion (2026-10-05 11:21), 3141 s.

Archivos de entrada: Lote1_Transcripcion_SIMULADO_v2.xlsx y

Registro_Sesiones_Piloto_SIMULADO_v4.xlsx. Escrita solo en

evidencias/simulado_demostracion/20261005_demostracion/; no se tocó corpus/real/,

logs/v3_real/ ni las carpetas privadas, y nada se registró como real.

Advertencias (leer antes de las cifras)

- Las frases del lote son generadas y no miden lenguaje real. Las escribió quien preparó el libro de prueba (varias son idénticas a frases del corpus sintético); las cifras de las etapas 2 y 3 no dicen nada sobre cómo escribe la gente de Juliaca.
- Las consultas de las sesiones son el texto de las tarjetas, con el prefijo «[SIMULACIÓN...]», así que acertarlas es trivial; además la prueba final de la etapa 5 usa un predictor simulado, no el modelo. Su exactitud no evalúa ningún modelo.
- Las compuertas aparecen como «Cumplida (Simulado)» y no cuentan como reales. Hoy las compuertas cumplidas con datos reales siguen siendo 0 de 7 (logs/avance/estado_compuertas.md).
- La revisión de etiquetas fue automática (no humana) y el modelo «congelado» es un marcador de texto con otro nombre; el modelo real no se congeló.

Resultados por etapa (todos SIMULADOS)

Etapa	Estado	Resultado	Tiempo y notas
1. Ingesta del libro (--libro, --demo-simulada)	Ejecutada (Simulado)	25 participantes Transcritos; 273 frases validadas; 7 blancos derivados; 12 frases idénticas al corpus sintético (fuga); «Listo para la Parte B»: SÍ (transcritos 25/15, intenciones con menos de 3 frases: 0)	2 s
1b. Revisión de etiquetas SIMULADA y --aplicar-revision	Ejecutada (Simulado)	261 OK, 12 DESCARTAR → 261 frases en lote1_real_final.csv. Sin segunda revisora ni kappa: no hubo revisión humana	2 s. La «revisión» es automática: no mide la calidad de las etiquetas.
2. Partición v3 con el lote simulado (split_corpus_v3.py)	Ejecutada (Simulado)	entrenamiento 708 (sintético), validación 110 y test 151 (frases del lote simulado); 54 intenciones en cada partición; sin frases repetidas entre particiones	2 s. Verificaciones de la partición superadas (si fallaran, el script no escribe).
3a. Evaluación en validación con la configuración ya elegida (eval_real.py --fase seleccion --configuracion-fija)	Ejecutada (Simulado)	Rasa/DIET 150,64,20: F1 macro validación = 0.8436; SVM (C = 10): F1 macro validación = 0.7475. Una combinación por método; no se repitió la grilla (12 combinaciones de Rasa y 3 de SVM)	466 s
3b. Umbral de confianza elegido sobre validación (fallback_threshold.py)	Ejecutada (Simulado)	t = 0.5; puntaje en validación 76.0 (sin umbral: 62.0)	2 s. Se eligió y se congeló solo con la validación, antes de evaluar el test; se aplicó al test después, ver 3d.
3c. Evaluación del test, UNA sola vez (eval_real.py --fase test)	Ejecutada (Simulado)	Rasa/DIET F1 macro test = 0.8206 (IC95 % [0.7318, 0.8452]); SVM = 0.8094 (IC95 % [0.7122, 0.8507]). Veces evaluado: {'rasa': 1, 'svm': 1}	2656 s. Cifras sobre frases generadas: no miden lenguaje real.
3d. Umbral aplicado a las predicciones del test ya guardadas (fallback_threshold.py --fase test --demo-simulada)	Ejecutada (Simulado)	t = 0.5: cobertura 84.2%, precisión de lo respondido 91.8% (sin umbral 83.2%), errores atrapados 15.0 y respuestas correctas perdidas 8.8 por semilla; puntaje 96.0 (sin umbral 74.8)	2 s. No se reentrenó ni se evaluó el test otra vez: veces evaluado sigue en {'rasa': 1, 'svm': 1}.
4. Modelo de demostración congelado (congelar_modelo.py --demo-simulada)	Ejecutada (Simulado)	modelo_demostracion_SIMULADO.tar.gz (sha256 024eaa6df478...), umbral t = 0.5; no es el modelo real y no existe logs/v3_real/modelo_congelado.json	2 s. El «modelo» es un archivo de texto con otro nombre: no se guarda ningún modelo Rasa entrenado.
5. Análisis del registro de sesiones simulado (analizar_piloto.py --demo-simulada)	Ejecutada (Simulado)	n = 60 sesiones elegibles (EJ01 excluida); tiempo: Wilcoxon de rangos con signo (unilateral), p = 8.145e-12, reducción de medias 98.1 %; satisfacción: alfa de Cronbach (ítems 1–8) = 0.549, ítem 9 frente a P10 p = 0.0005216; prueba final con un predictor SIMULADO: accuracy 0.606, F1 macro 0.513 (180 consultas)	8 s. Las consultas son el texto de la tarjeta con el prefijo «[SIMULACIÓN...]»: acertarlas es trivial y el predictor es simulado, no el modelo.
6. Tablero de compuertas (estado_compuertas.py --demo-simulada)	Ejecutada (Simulado)	Compuertas cumplidas con datos REALES: 0 de 7; con datos simulados: 3. G1 Cumplida (Simulado); G2 En curso (Simulado); G3 Cumplida (Simulado); G4 Pendiente (sin evidencia); G5 En curso (Simulado); G6 Pendiente (sin evidencia); G7 Cumplida (Simulado)	2 s. Las compuertas «Cumplida (Simulado)» no cuentan como reales.

Tablero de compuertas de la demostración

Compuerta	Estado	Datos	Nota
G1 Lote 1 completo	Cumplida (Simulado)	Simulado	Transcritos 25/15 (≥ 15); intenciones con menos de 3 frases: 0.
G2 Parte B ejecutada	En curso (Simulado)	Simulado	Ingesta sin errores bloqueantes; falta la marca del tesista logs/avance/revision_pii.txt (archivo con su nombre y fecha, después de leer el reporte de datos personales).
G3 Calidad con lenguaje real	Cumplida (Simulado)	Simulado	Ciclos de refinamiento: 0/2. Única evaluación del test real: F1 macro = 0.8206 (≥ 0.75).
G4 Respuestas verificadas	Pendiente (sin evidencia)	—	—
G5 Modelo congelado	En curso (Simulado)	Simulado	Modelo de demostración congelado; no hay evidencia simulada de G3 o G4 con la que compararlo.
G6 Pre-piloto	Pendiente (sin evidencia)	—	—
G7 Sesiones	Cumplida (Simulado)	Simulado	60 sesiones elegibles y completas (meta 60).

Compuertas cumplidas con datos reales: 0 de 7; con datos simulados: 3 (no cuentan como reales).

Aislamiento verificado. Se comprobó con SHA-256, antes y después, 55 archivos de corpus/real/, logs/v3_real/, docs/lote_real_1/privado/, docs/piloto/privado/, logs/avance/, data/, corpus/v3_real/, models/: ninguno cambió. Los modelos Rasa se entrenaron en una carpeta temporal fuera del repositorio y se borraron; la carpeta de la ejecución no contiene ningún .tar.gz de Rasa.

Fricciones encontradas

Obstáculos del flujo, con la medida tomada y su estado. La ejecución completa no falló en el primer intento; la mayoría se detectó al diseñar la demostración, y las limitaciones son propias de trabajar con datos simulados.

Fricción	Detectada	Medida tomada	Estado
La ingesta advirtió 12 frases del lote simulado idénticas a frases del corpus sintético: pasarían a validación/test y provocarían fuga (la partición se niega a continuar con ellas)	durante la ejecución	En la revisión de etiquetas SIMULADA se descartaron (DESCARTAR), como haría una revisora; el resto se marcó OK	Resuelta en la demostración
No hay revisión humana de etiquetas en una demostración: --aplicar-revision exige una decisión por frase y la persona que las toma no existe	por diseño	Se simuló una revisión automática (todas OK salvo las fugas, DESCARTAR) y se rotuló como simulada en cada fila; los resultados siguientes no dicen nada sobre la calidad de las etiquetas	Limitación declarada

Fricción	Detectada	Medida tomada	Estado
Los modelos Rasa entrenados en la evaluación son archivos .tar.gz pesados; si quedaran en models/ o en evidencias/ podrían subirse al repositorio	al diseñar	Se entrenaron en una carpeta temporal fuera del repositorio, que se borra al terminar; el modelo congelado de la demostración es un marcador de texto con otro nombre	Resuelta
Marcar cada archivo al terminar su etapa cambia nombres (_SIMULADO) y agrega la columna ESTADO a los CSV: la etapa siguiente ya no encontraría sus entradas	al diseñar	Cada etapa escribe sin marcar y el marcado se hace una sola vez al final (opción interna --demo-sin-marcar); el tablero, que sí necesita los nombres marcados, se ejecuta después	Resuelta
congelar_modelo.py --demo-simulada trataba --salida como carpeta aunque se le pasara un archivo .json: habría creado una carpeta con el nombre del archivo	al diseñar	--salida acepta una carpeta o un .json de la carpeta de demostración (se usa la carpeta); cubierto por la prueba de humo	Resuelta
eval_real.py solo sabía recorrer la grilla completa (12 combinaciones de Rasa/DIET y 3 valores de C del SVM), que la demostración no debe repetir	al diseñar	Se agregaron --configuracion-fija (150,64,20) y --svm-c (10); sin ellas el comportamiento no cambia	Resuelta
El marcado renombró el «modelo» .tar.gz y el congelamiento quedó apuntando a un archivo que ya no existía	en un ensayo previo	Los nombres que ya contienen _SIMULADO no se renombren, y el congelamiento de demostración no referencia archivos que se modifican al marcar (el umbral se copia adentro)	Resuelta
El marcado no cubría los .yaml (la configuración de cada entrenamiento de Rasa), que podían quedar sin marcador	al diseñar	Los .yaml llevan el marcador como comentario en la primera línea (siguen siendo YAML válido)	Resuelta
El tablero buscaba los archivos simulados un solo nivel adentro, habría mezclado ejecuciones distintas y además evaluaba el mundo real	al diseñar	Búsqueda recursiva restringida a la carpeta de la ejecución y, en el modo de demostración, el mundo real no se evalúa	Resuelta
Los registros de entrenamiento y de las etapas guardaban rutas absolutas del equipo con el nombre de usuario de Windows	durante la ejecución	Se reemplazan por rutas relativas al repositorio y «<usuario>» antes del marcado final (el congelamiento de demostración sigue siendo verificable)	Resuelta
La demostración tardó 52 minutos: el test entrena Rasa/DIET con 5 semillas de 150 épocas (2656 s) y la validación otro modelo (466 s)	durante la ejecución	No se redujo: bajar las semillas cambiaría el procedimiento de repeticiones del protocolo. Se ejecutó en segundo plano	Limitación declarada
G2 (marca del tesista), G4 (hoja del TUPA) y G6 (registro de pre-piloto) no pueden cumplirse con datos simulados: dependen de una acción humana o de archivos que la demostración no simula	por diseño	Quedan «En curso (Simulado)» o «Pendiente (sin evidencia)»; no se fabricó ninguna marca humana	Limitación declarada
G3 sale «Cumplida (Simulado)» con 0 ciclos de refinamiento registrados porque la demostración no refina; el F1 alto sale de frases generadas, muy parecidas a las del entrenamiento	por diseño	Se advierte en este informe; no cuenta como real	Limitación declarada
La prueba final de las sesiones usa un predictor SIMULADO (el modelo congelado de demostración es un marcador de texto) y las consultas son el texto de las tarjetas	por diseño	Se rotula en este informe y en el análisis; su exactitud no evalúa ningún modelo	Limitación declarada

Fricción	Detectada	Medida tomada	Estado
fallback_threshold.py --fase test anotaba la aplicación del umbral como una evaluación más del test (rasa_umbral), lo que se leía como una segunda evaluación, y no comprobaba que las predicciones fueran las de la evaluación única ni que el umbral se hubiera congelado antes del test	al verificar el flujo	La aplicación se anota aparte (aplicaciones_de_umbral) y no suma una evaluación; se comprueba que sean las mismas semillas, el mismo número de frases y la misma huella SHA-256, y que el umbral sea anterior al test; eval_real.py --fase test lo aplica en la misma pasada si ya hay un umbral congelado	Resuelta
En esta primera pasada de la demostración el umbral se eligió solo con la validación y no se aplicó al test (por instrucción)	por instrucción	Se aplicó después, sobre las predicciones ya guardadas y en la misma carpeta, con fallback_threshold.py --fase test --demo-simulada (1,7 s, sin reentrenar ni evaluar de nuevo; etapa 3d). Esas predicciones se guardaron antes de que se registraran huellas: la integridad se comprobó por semillas y número de frases, no por huella	Resuelta (integridad por huella: limitación declarada)

5.8 Resultados reales (lotes 1 y 2) y decisión sobre G3 (REAL, a 8 de octubre de 2026)

Estos resultados provienen de personas reales y no de la demostración simulada de la Sección

5.7. Se presentan con su incertidumbre y sin extrapolarlos.

Concepto	Resultado	Nota
Participantes	32 (lote 1: P01–P25; lote 1b: P26–P28; lote 1c: P29–P32)	Muestra de conveniencia, adultos.
Frases reales	189 transcritas; 3 descartadas (R0147, R0182, R0183); R0136 excluida por ambigua (mismo texto con dos etiquetas); 185 activas: 71 en validación y 114 en test	Cada frase es su propio grupo de partición.
Entrenamiento	707 frases sintéticas (708 menos U0554, duplicada de una frase real)	Las frases reales no se usan para entrenar en esta partición.
Lote 1: evaluación en test real (una sola vez)	F1 macro 0.687 (Rasa/DIET); criterio ≥ 0.75 : NO cumplido	IC95 % bootstrap 0.570–0.707; 0.75 queda fuera del intervalo (solo el 0.1 % de las remuestras lo alcanza). El intervalo está sesgado a la baja porque 48 de 54 intenciones tienen solo 2 frases de test.
Sensibilidad (no comparable)	Validación cruzada agrupada: 0.787	Incluye frases sintéticas; sugiere un desplazamiento entre lo sintético y lo real. No sustituye al F1 del test real.
Ciclos de refinamiento	0 de 2	No se abrió ningún ciclo; no se repitió la evaluación del test.
Hallazgo «gracias»	Las personas usan «gracias» para agradecer y también para despedirse	La confusión despedida ↔ agradecimiento se reporta aparte como esperada; las respuestas de ambas intenciones sirven para las dos lecturas.

Concepto	Resultado	Nota
Respuestas verificadas (G4)	28 filas confirmadas por el tesista; 0 de 44 respuestas con [Verificar]	Todas se contrastaron con el TUPA y con los canales oficiales el 08/10/2026; constancia_domiciliaria: costo y plazo confirmados por el tesista.
Lote 2: participantes y test	25 participantes (P33–P57); 280 frases; 13 excluidas por duplicado exacto con el entrenamiento; 267 en test; 56 de 56 situaciones	Misma lista de 56 situaciones del lote 1 (independiente por personas, no por situaciones). Revisión de etiquetas por una sola persona, sin cambios.
Lote 2: evaluación única (G3)	F1 macro 0.9072 (Rasa/DIET); criterio ≥ 0.75 : CUMPLIDO	IC95 % bootstrap por frases [0.8626; 0.9290] y por participantes [0.8524; 0.9385]. Exactitud 0.8876 (237/267). Con 54 intenciones, 0.9240 (complementario).
Lote 2: cobertura y precisión (t = 0.50)	Cobertura 92.9 % (248 respondidas); precisión de lo respondido 95.6 % (237 aciertos, 11 errores); 19 abstenciones (7.1 %)	Cifras recalculadas de las predicciones guardadas; la sección equivalente del script de evaluación es un artefacto.
Lote 2: línea base SVM (informativa)	F1 macro 0.8925; McNemar DIET frente a SVM p = 0.541	Sin diferencia demostrable; G3 se decide solo con DIET.

Desviación del perfil de participantes. Tres participantes (P08, P24 y P25) indicaron no vivir en Juliaca, lo que se aparta del criterio «adultos de Juliaca»: 3 de 32 participantes (9.4 %) y 20 de 186 frases (10.8 %). Se conservan en el corpus y se declara la desviación; la lectura de los resultados debe considerarla.

Criterio de trámite reciente. Haber realizado un trámite en los últimos 12 meses (variable tramite_12m) no es criterio de inclusión: se registra solo como observación (P26, P27 y P29–P32 respondieron «No») y no constituye desviación.

Limitación de reparto. Cada frase es su propio grupo de partición; 28 de 31 participantes y 52 de 56 situaciones tienen frases tanto en validación como en test. Las particiones no son independientes por participante ni por situación, y la muestra es pequeña y de conveniencia: el F1 real tiene alta varianza.

Decisión sobre G3 (ejecutada). El F1 macro del test del lote 1 (0.687) no alcanzó 0.75; ese test no se repitió ni se bajó el umbral. Conforme a lo declarado antes de medir, se aplicó

un lote 2: (a) conjunto de prueba nuevo e independiente por personas (P33–P57); (b) entrenamiento que incorpora las frases reales del lote 1, lo que modifica la regla de la V1.2 («las frases reales no se usan para entrenar») y convierte el test del lote 1 en dato de desarrollo; (c) modelo, umbral y datos congelados con sha256 antes de abrir el test; (d) G3 medida una sola vez, solo sobre el lote 2. Estado: ejecutado; G3 cumplida con la medición del lote 2 (F1 macro 0.9072).

Lote 2: diseño. 25 participantes nuevos (P33–P57) escribieron 280 frases sobre las mismas 56 situaciones del lote 1 (formularios A–E). La tesista revisó las etiquetas sin segunda revisión: 280 aceptadas, 0 cambiadas, 0 descartadas (el kappa de 1.000 es trivial y no cuenta como acuerdo entre revisores). Se excluyeron del test 13 frases idénticas a las del entrenamiento por coincidencia exacta normalizada (7 sintéticas y 6 reales del lote 1), nunca por predicciones; el test quedó con 267 frases, 25 participantes y 56 de 56 situaciones (4 a 5 frases por situación). El entrenamiento fue de 943 frases (707 sintéticas, 185 reales del lote 1 y 51 sintéticas del ciclo de refinamiento 1, que se detuvo con una mejora de +0.012, menor a 0.02). DIET 100/64/20 (semilla 42), umbral $t = 0.50$ y el modelo SVM de referencia se congelaron con sha256 antes de abrir el test; 16 verificaciones previas dieron OK.

Lote 2: resultado (evaluado una sola vez). Rasa/DIET obtuvo F1 macro 0.9072, con IC95 % bootstrap [0.8626; 0.9290] por frases y [0.8524; 0.9385] por participantes; el límite inferior por participantes supera 0.75, así que G3 queda cumplida. Exactitud 0.8876 (237 aciertos y 30 errores). La cifra oficial cuenta cada abstención («nlu_fallback», 19 de 267, 7.1 %) como error y promedia 55 etiquetas; calculada sobre las 54 intenciones con las mismas predicciones sería 0.9240 (dato complementario). Cobertura 92.9 % (248

respondidas) y precisión de lo respondido 95.6 % (237 aciertos y 11 errores). 30 intenciones tienen $F1 = 1$ y 3 tienen $F1 < 0.75$ (licencia_funcionamiento_plazo 0.57, fuera_de_alcance 0.64 y denuncia_seguridad_ciudadana 0.67), con solo 4 a 5 frases por intención. Despedida ($n = 5$): 4 bien y 1 como otra intención; agradecimiento ($n = 5$): 4 bien y 1 como despedida. El SVM, solo informativo, dio 0.8925; DIET frente a SVM en McNemar: solo SVM acierta 10 y solo DIET acierta 14 ($p = 0.541$), sin diferencia demostrable.

Lote 2: cómo leer el resultado. (1) Es una medición válida en su diseño, pero no prueba generalización a situaciones nuevas: las 56 situaciones son las mismas del lote 1 (independencia por personas, no por situaciones); eso lo pone a prueba el pre-piloto (G6). (2) No es comparable con el 0.687 del lote 1: aquel $F1$ se calculó con argmax y con un entrenamiento sin frases reales; este incluye la abstención y se entrenó con 943 frases, incluidas las reales del lote 1. (3) La validación cruzada del lote 1 (0.787–0.799) sugería un valor menor; la diferencia se explica en buena parte por el diseño. (4) Una sola revisora de etiquetas y ningún cambio sobre 280 frases: no hay validación independiente de las etiquetas. (5) Tras la evaluación no se re-entrenó, no se cambió el umbral ni se repitió la medición, y no se abrieron los textos de los 30 errores (se listan solo por identificador). (6) Incidente: durante la preparación se mostró por descuido una frase del lote 2 (P33, S01); no intervino en predicciones ni ajustes y quedó registrada en el registro de incidentes. (7) La sección «cobertura y precisión» que imprime el script de evaluación es un artefacto (98.9 %); se usan las cifras recalculadas de las predicciones guardadas.